



國立臺灣科技大學

電 機 工 程 系

碩士學位論文

學號：M11307123

基於雙延遲深度確定性策略梯度與分散式共識修正

機制之配電網路復電策略研究

**Restoration Strategy for Distribution Networks
Based on Twin Delayed Deep Deterministic Policy
Gradient and Distributed Consensus Correction
Mechanism**

研 究 生：呂仲軒

指導教授：劉建宏 博士

中華民國 一百一十五年 七 月

摘要

近年來，極端氣候與意外故障頻繁引發配電系統大規模停電，對社會經濟與公共安全造成嚴重威脅。如何在災害發生後迅速且有效地恢復關鍵負載供電，已成為強化與評估「電網韌性」的指標性任務。傳統仰賴數學規劃的復電策略，在面對拓撲變更與環境不確定性時，往往難以滿足即時決策的需求，而分散式能源的大量併網更帶來了固有的隨機性，進一步加劇了復電策略制定的困難度。

為突破上述瓶頸，在分散式訓練分散式執行（DTDE）下，提出整合策略共識（PC）、記憶網路與雙延遲深度確定性策略梯度（TD3）三大模組之強化學習架構。復電過程形式化為部分可觀測馬可夫決策過程（POMDP），並建構多維複合特徵觀測空間，深度融合電網圖結構特徵與代理人歷史記憶。圖神經網路（GNN）採用固定自身權重之加權局部聚合，使代理人在整合鄰居資訊的同時保持對本地狀態的精確感知；門控循環單元（GRU）從序列樣本中提取時序相關性，精準捕捉電網逐步復電過程中的複雜動態行為，並作為 POMDP 之信念狀態（Belief State）近似器。

在演算法設計上，本架構採用雙延遲深度確定性策略梯度（TD3）取代傳統確定性策略梯度（DPG），透過截斷雙 Q 學習、延遲策略更新與目標策略平滑化三大機制有效抑制估計偏差。策略共識（PC）機制採固定 15 回合週期定期整合鄰居代理人參數，確保代理人間的協調對齊；收斂判定採四輪連續達標確認機制，保障最終輸出策略的穩健性與泛化能力。精英池與一般池雙池經驗回放記憶體架構透過嚴格四項菁英篩選條件解決稀疏獎勵問題。

本架構以劃分為 5 個微電網代理人的 IEEE 123-bus 系統進行驗證，在隨機初始 SOC 40%-60%條件下達到 100%之 24 小時全程關鍵負載復電率，顯示此策略能在不確定的故障情境中快速收斂，並給出兼具高穩定性與高效率的復電策略。

關鍵詞：電網韌性、多代理人強化學習、部分可觀測馬可夫決策過程、分散式訓練分散式執行、圖神經網路、門控循環單元、雙池經驗回放記憶體

ABSTRACT

Extreme weather events and unexpected equipment failures have increasingly caused large-scale outages in power distribution systems, posing severe threats to socioeconomic stability and public safety. Restoring critical load supply rapidly and effectively following such events has become a key benchmark task for strengthening and evaluating power grid resilience. Traditional restoration strategies based on mathematical programming often fail to meet real-time decision-making requirements when confronted with topology changes and environmental uncertainty. The widespread integration of distributed energy resources (DERs) further introduces inherent stochasticity, compounding the difficulty of formulating effective restoration strategies.

To address these challenges, this study proposes a reinforcement learning architecture under Decentralized Training Decentralized Execution (DTDE), integrating three core modules: Policy Consensus (PC), a memory network, and Twin Delayed Deep Deterministic Policy Gradient (TD3). The restoration process is formulated as a Partially Observable Markov Decision Process (POMDP), with a multi-dimensional composite feature observation space constructed to deeply integrate power grid topological features with agent historical memory. A Graph Neural Network (GNN) employs weighted local aggregation with a fixed self-weight, enabling each agent to incorporate neighbor information while maintaining precise awareness of its local state. A Gated Recurrent Unit (GRU) extracts temporal dependencies from sequential samples, accurately capturing the complex dynamic behavior of the incremental grid restoration process and serving as a belief state approximator for the POMDP.

In terms of algorithmic design, this framework employs Twin Delayed Deep Deterministic Policy Gradient (TD3) in place of the conventional Deterministic Policy Gradient (DPG), effectively suppressing estimation bias through three mechanisms: Clipped

Double-Q learning, delayed policy update, and target policy smoothing. The Policy Consensus (PC) mechanism integrates neighboring agent parameters at a fixed interval of 15 episodes to ensure inter-agent coordination alignment; convergence assessment employs a four-round consecutive confirmation mechanism to guarantee the robustness and generalizability of the final output policy. A dual-pool experience replay architecture—comprising an elite pool and a normal pool—addresses the sparse reward problem through four strict elite selection criteria.

The proposed framework is validated on the IEEE 123-bus test system partitioned into five microgrid agents. Under randomized initial State of Charge (SOC) conditions between 40%-60%, a 24-hour full-cycle critical load restoration rate of 100.0% is achieved, demonstrating that the proposed strategy converges rapidly under uncertain fault scenarios and yields restoration policies with both high stability and high efficiency.

Keywords: power grid resilience, multi-agent reinforcement learning, partially observable Markov decision process, decentralized training and decentralized execution, graph neural network, gated recurrent unit, dual-pool experience replay buffer

目錄

摘要.....	i
ABSTRACT.....	ii
目錄.....	iv
表目錄.....	viii
圖目錄.....	ix
第一章 緒論.....	1
1.1 研究背景與動機.....	1
1.2 文獻回顧.....	1
1.3 研究目的.....	4
1.4 研究貢獻.....	4
1.5 論文架構.....	5
第二章 復電問題定義.....	6
2.1 系統假設與情境設定.....	6
2.2 復電問題之數學模型與總體目標.....	7
2.2.1 系統架構與圖模型.....	7
2.2.2 目標函數.....	8
2.3 動作空間.....	9
2.4 系統運作與物理約束條件.....	9
2.5 不確定性來源與部分可觀測性.....	10
第三章 強化學習模型設計.....	12
3.1 決策過程框架.....	12
3.1.1 馬可夫決策過程 (Markov Decision Process, MDP)	13
3.1.2 部分可觀測馬可夫決策過程 (POMDP)	13

3.1.3 分散式部分可觀測馬可夫決策過程 (Dec-POMDP)	14
3.2 多代理人強化學習訓練架構	17
3.2.1 集中式訓練分散式執行 (CTDE)	17
3.2.2 分散式訓練分散式執行 (DTDE)	18
3.2.3 本研究採用 DTDE 之理由	18
3.3 策略梯度方法與 Actor-Critic 演進	18
3.3.1 確定性策略梯度 (Deterministic Policy Gradient, DPG)	20
3.3.2 深度確定性策略梯度 (Deep Deterministic Policy Gradient, DDPG)	20
3.3.3 雙延遲深度確定性策略梯度 (TD3)	22
3.4 時序記憶模型	25
3.4.1 長短期記憶網路 (LSTM)	26
3.4.2 門控循環單元 (GRU)	27
3.4.3 LSTM 與 GRU 比較與選用分析	28
3.5 圖神經網路 (Graph Neural Network, GNN)	29
3.5.1 圖卷積網路	30
3.5.2 圖聚合設計	30
3.5.3 本研究之加權局部聚合設計	31
3.6 多代理人策略協調機制	33
3.6.1 策略共識機制 (Policy Consensus, PC)	34
3.6.2 連勝鎖 (Streak Lock) 機制	35
3.7 雙池經驗回放記憶架構	36
3.7.1 雙池架構設計	36
3.7.2 四項精英篩選條件	37
第四章 模擬環境建立與實作方法	39
4.1 電力系統圖論基礎	39
4.1.1 電網圖模型	40
4.1.2 連通分量孤島偵測	40

4.1.3 代理人通訊圖與共識矩陣	41
4.2 PandaPower 潮流分析工具	42
4.2.1 電力系統模擬工具比較與選用	43
4.2.2 潮流計算	44
4.2.3 DER 出力不確定性模型	45
4.3 IEEE 123-bus 系統設定	46
4.3.1 IEEE 123-bus 測試系統	47
4.3.2 微電網分區與關鍵負載設計	47
4.3.3 DER 配置設計與 ESS 容量分析	48
4.3.4 STATCOM 建模方式	51
4.3.5 任務難度的多維結構	51
4.4 MicrogridEnv 環境模組	53
4.4.1 Gym 環境介面	53
4.4.2 局部觀測向量結構	54
4.4.3 環境初始化 (reset)	55
4.4.4 Virtual Slack 動態指派機制	55
4.4.5 動作執行與約束驗證	56
4.4.6 獎勵函數設計	57
4.5 訓練流程	60
4.5.1 序列訓練結構	60
4.5.2 探索噪聲與訓練穩定機制	61
4.5.3 完美收斂判定與四輪確認機制	62
4.5.4 主要超參數設定與訓練流程整合	63
第五章 模擬結果與分析	68
5.1 評估指標定義	69
5.2 記憶模組與演算法之固定初始 SOC	70
5.2.1 固定 SOC 條件的核心觀察	72

5.3 記憶模組與演算法之隨機初始 SOC	72
5.3.1 固定 SOC 與隨機 SOC 的對比分析	75
5.4 PC 共識參數比較	75
5.4.1 主方法 PC 0.8/0.85 設計驗證	78
5.5 GNN 自身/鄰居聚合比例比較	78
5.5.1 最優 α_{self} 的選定	81
5.6 代理人行為分析	81
5.6.1 PV 出力與 ESS 充放電行為	82
5.6.2 夜間放電與 ESS 能量管理	82
第六章 結論	84
6.1 研究成果與貢獻	84
6.1.1 架構設計貢獻	84
6.1.2 實驗結果貢獻	85
6.2 未來展望	85
參考文獻	87

表目錄

表 4.1 跨 MG 通訊拓樸	42
表 4.2 電力系統模擬工具功能比較	43
表 4.3 訓練環境難度來源與對應架構設計	52
表 4.4 局部觀測向量各區塊結構	54
表 4.5 複合獎勵函數設計	58
表 4.6 主要超參數設定	63
表 5.1 固定初始 SOC 訓練結果彙整	70
表 5.2 隨機初始 SOC 訓練結果彙整	73
表 5.3 固定初始 SOC 與隨機初始 SOC 後 500ep GoodAvg 對比	75
表 5.4 PC 共識參數訓練結果	76
表 5.5 各 a_{self} 訓練結果彙整	79

圖目錄

圖 3.1 DDPG 機制架構.....	22
圖 3.2 TD3 機制架構.....	24
圖 3.3 LSTM 模組架構圖	27
圖 3.4 GRU 模組架構圖	28
圖 3.5 GNN+GRU 架構.....	33
圖 3.6 Agents 資訊流動.....	35
圖 5.1 IEEE 123-bus 配電測試系統	69
圖 5.2 固定初始 SOC 之 24 小時恢復曲線.....	71
圖 5.3 固定初始 SOC 之 Reward 曲線.....	72
圖 5.4 固定初始 SOC 之 SOC std 曲線.....	72
圖 5.5 隨機初始 SOC 之 24 小時恢復曲線.....	74
圖 5.6 隨機初始 SOC 之 Reward 曲線.....	74
圖 5.7 隨機初始 SOC 之 SOC std 曲線.....	75
圖 5.8 各 PC 共識參數訓練之 24 小時恢復曲線.....	77
圖 5.9 各 PC 共識參數訓練之 Reward 曲線.....	78
圖 5.10 各 PC 共識參數訓練之 SOC std 曲線.....	78
圖 5.11 各 a_{self} 訓練配置之 24 小時恢復曲線.....	80
圖 5.12 各 a_{self} 訓練配置之 Reward 曲線	80
圖 5.13 各 a_{self} 訓練配置之 SOC std 曲線	81
圖 5.14 PV 曲線、load 曲線、一般負載截斷量.....	83
圖 5.15 SOC 電量曲線	83
圖 5.16 SOC 充/放電曲線.....	83

第一章 緒論

1.1 研究背景與動機

隨著氣候變遷加劇，颱風、地震、洪水等極端天氣事件的頻率與強度持續上升，配電系統面臨大規模停電的風險日益增高。這類災害往往在短時間內導致廣泛的饋線損毀與拓樸斷裂，使得傳統以固定電網拓樸為前提的保護與控制策略完全失效。更關鍵的是，醫院、急救中心、緊急通訊設施等關鍵負載若無法在災後迅速恢復供電後持續運作，將對社會公共安全造成嚴重威脅，甚至引發次生災害[1]。

為應對上述挑戰，現代配電系統大量導入分散式能源（Distributed Energy Resource, DER），包括太陽能（Photovoltaic System, PV）與儲能系統（Energy Storage System, ESS）等設備。這些 DER 不僅能在主電網失聯後提供孤島運轉（Islanded Operation）所需的局部電源，更賦予配電網路在災後自主復電的能力。然而，DER 出力的間歇性與不確定性，使得復電策略的制定面臨嚴峻的隨機性挑戰，傳統依賴精確模型的離線規劃方法已難以適應此類高度動態的故障場景[2]。

在多代理人強化學習（Multi-agent Reinforcement Learning, MARL）領域，要在連續狀態與動作空間中引導多個代理人學習高效的協同復電策略，至今仍是極具挑戰性的課題。現有大多數方法依賴集中式訓練（Centralized Training with Decentralized Execution, CTDE）框架，在訓練階段需要全局資訊，難以延伸至具有通訊頻寬限制與隱私保護需求的實際分散式場景。本研究正是為突破此一瓶頸而提出[3]。

1.2 文獻回顧

Panteli 與 Mancarella [1]系統化定義電力系統韌性為對高衝擊低概率事件的預測、吸收與快速恢復能力，並明確區別韌性與傳統可靠性的概念差異，強調電力基礎設施除應對已知故障外，更需具備應對極端災害的適應與恢復能力。

在方法論方面，現有研究主要可分為數學規劃方法與深度強化學習方法兩大路

線。數學規劃方法以混合整數線性規劃 (Mixed-Integer Linear Programming, MILP) 或混合整數非線性規劃 (Mixed integer nonlinear programming, MINLP) 為基礎，制定離線的最優開關序列或資源排程，在確定性環境下能提供理論最優解。Khodaei [4] 提出復電導向的微電網最優排程模型，採用 Benders 分解搭配強健優化方法同時處理負載、可再生能源出力與孤島持續時間三類不確定性，實現主網斷電後的快速孤島切換與最小化負載削減。然而，此類方法的計算複雜度隨系統規模指數增長，且在面對動態拓撲變更與即時環境不確定性時難以滿足快速決策的需求。

深度強化學習 (Deep Reinforcement Learning, DRL) 以馬可夫決策過程 (Markov Decision Process, MDP) 為基本框架[5]，憑藉其無模型 (Model-free) 與資料驅動的優勢，近年來被廣泛應用於電力系統控制問題 [6, 7]。相較於傳統數學規劃方法，DRL 無需對環境建立精確數學模型，能以訓練好的神經網路進行前向計算生成即時決策，顯著降低執行階段的計算代價。

在配電網關鍵負載復電任務方面，Fan et al. [6] 提出記憶式圖強化學習方法，將含 DER 不確定性的關鍵負載復電問題建模為部分可觀測馬可夫決策過程 (Partially Observable Markov Decision Process, POMDP)；據其指出，此為將 DER 不確定性問題轉化為環境部分可觀測性問題的早期嘗試之一。其觀測空間融合電網圖結構特徵與時序記憶資訊，以圖卷積網路 (Graph Convolutional Network, GCN) 提取電網拓撲的潛在特徵，以長短期記憶模型 (Long Short-Term Memory, LSTM) 補償 DER 不確定性所造成的資訊缺失，並在 IEEE 123-bus 系統上驗證了有效性。Si et al. [7] 進一步指出，在配電網復電任務中開關動作會導致微電網邊界動態變更，使代理人的觀測維度隨之改變；其提出的動態代理人網路 (Dynamic Agent Network, DAN) 架構以注意力機制聚合任意數量的鄰居代理人特徵，並結合動作遮罩機制過濾不符合安全約束的動作，有效處理了上述動態維度變化問題。

在多代理人強化學習 (MARL) 框架方面，Lowe et al. [8] 提出 MADDPG，採用集中式訓練分散式執行 (CTDE) 的設計：訓練階段設立集中式評估者網路 (Critic) 存

取所有代理人的觀測與動作以緩解非穩態問題，執行階段各代理人僅依賴本地觀測獨立決策。CTDE 框架雖能提供穩定的訓練梯度，但其對集中式全局通訊的依賴隨代理人數量增加而加劇，在通訊頻寬受限或隱私保護需求的實際場景中可行性不足。

針對上述限制，D.Hu et al. [3]提出 MASAC-HGRN，在分散式訓練與分散式執行（Decentralized Training Decentralized Execution, DTDE）框架下處理電壓無功控制（Volt-Var Control, VVC）問題；訓練與執行兩個階段均不依賴全局資訊，各代理人僅利用本地觀測與有限鄰居通訊進行決策，在 IEEE 33-bus 與 123-bus 配電系統上驗證了 DTDE 框架的有效性與強健性。

在 DTDE 的理論基礎方面，Y.Hu et al. [9]將確定性策略梯度方法延伸至有向圖上的分散式 MARL 領域，提出 D3-AC 演算法：於線性 Critic 近似假設下建立局部 DPG 定理並獲得漸近收斂保證；並進一步證明對於同質代理人（Homogeneous Agents），最優解可限制在所有代理人共享相同策略的空間內求得，從而為策略共識步驟提供了理論依據。實作層面採用 GCN 設計 Critic 以處理可擴展性問題，並在每個訓練回合結束後對行為者網路（Actor）與 Critic 參數分別執行鄰域加權平均的共識更新，在標準 MARL 基準任務上取得了與集中式訓練基線相當的學習性能。

在演算法發展方面，Silver et al. [10]提出確定性策略梯度（Deterministic Policy Gradient, DPG）定理，指出確定性策略的性能梯度僅需在當前策略所輸出的單一動作點處評估，無需對整個動作空間積分；此設計使梯度估計的計算代價與動作維度呈線性關係，在高維連續動作空間中較隨機策略梯度方法具有顯著的樣本效率優勢，並以離線策略的 Actor-Critic 架構搭配探索噪聲實現充分探索。Lillicrap et al. [11]在 DPG 基礎上引入深度神經網路函數逼近器，提出深度確定性策略梯度（Deep Deterministic Policy Gradient, DDPG）；透過經驗回放記憶區打破時序相關性、軟更新目標網路提供穩定的時序差分（Temporal Difference, TD）訓練目標，使確定性策略梯度方法得以在高維連續控制問題上穩定訓練。然而，DDPG 在實際應用中仍存在 Q 值系統性高估與策略不穩定等問題。Fujimoto et al. [12]針對此提出（Twin Delayed Deep Deterministic

policy gradient, TD3)，透過截斷雙 Critic 網路（Clipped Double-Q Learning）、延遲策略更新與目標策略平滑化三項機制，有效抑制 Actor-Critic 框架中的函數逼近誤差累積，在連續控制基準任務上全面超越 DDPG。

綜觀上述文獻，現有 MARL 復電研究主要存在以下缺口：Fan et al. [6]與 Si et al. [7]均以單代理人 CTDE 框架為主，前者不具備多代理人協調能力，後者在訓練階段仍需集中式全局資訊；D.Hu et al. [3]雖驗證了 DTDE 在配電系統的可行性，但應用場景為穩態電壓控制而非災後動態復電；Y.Hu et al. [9]提供了 DTDE 的理論收斂保證，但其 Critic 設計依賴同質代理人可在本地推算其他代理人觀測的條件，在本研究的 DTDE 復電情境下並不成立。本研究正是為填補上述缺口而提出，具體貢獻詳見第 1.4 節。

1.3 研究目的

本研究旨在提出一套能在分散式訓練與分散式執行（DTDE）框架下實現多微電網協同復電的強化學習架構，具體目標包括：

- 在無中央 Critic 的條件下，實現 5 個微電網代理人的有效協同復電
- 以 POMDP 形式化建構含 DER 不確定性的復電問題，並設計能應對部分可觀測性的多維複合特徵觀測空間
- 以 TD3 取代傳統 DPG，提升在隨機初始條件下的訓練穩定性與泛化能力
- 透過系統性比較分析實驗，量化各模組對整體性能的獨立貢獻

1.4 研究貢獻

本研究的主要貢獻總結如下：

- 在分散式訓練分散式執行（DTDE）框架下，提出整合策略共識（Policy Consensus, PC）、GNN-GRU 記憶網路與 TD3 之多代理人強化學習架構——PC-Memory-TD3，在 DTDE 框架下實現含 ESS 調度與 Tie-line AND 投票的多微電網混合動作空間協同復電

- 設計 GNN-GRU 多模態記憶架構，融合空間圖結構模態與時序歷史記憶模態，有效應對 POMDP 的雙重部分可觀測性
- 引入 PC 策略共識機制搭配連續達標鎖定 (Streak Lock)，實現無集中式 Critic 的多代理人策略對齊
- 設計精英池雙池經驗回放記憶體架構，以四項 AND 篩選條件解決稀疏獎勵與樣本品質不均問題

1.5 論文架構

本論文共分六章：

- ◆ 第二章定義復電問題的數學模型與物理約束。
- ◆ 第三章介紹強化學習模型的理論背景，包含 MDP、POMDP、DPG 至 TD3 的演算法演進、LSTM 與 GRU 時序記憶、GNN 空間聚合、CTDE 與 DTDE 框架比較，以及雙池經驗回放記憶機制。
- ◆ 第四章說明模擬環境建立，包含圖論基礎、PandaPower 系統、IEEE 123-bus 配置、Gym 環境介面與獎勵函數設計。
- ◆ 第五章呈現實驗結果與系統性比較分析。
- ◆ 第六章總結研究成果並展望未來發展方向。

第二章 復電問題定義

本章將微電網群災後關鍵負載復電問題形式化為具備明確結構的數學模型，作為後續強化學習架構設計的理論基礎。首先定義系統運作的物理前提與情境假設，繼而建立狀態空間、動作空間與目標函數的形式化描述，並說明系統需遵循的物理與操作約束，最後闡述環境不確定性與部分可觀測性的來源，說明採用 POMDP 框架的必要性。

2.1 系統假設與情境設定

本研究以修正版 IEEE 123-bus 配電系統作為測試環境，假設在災害發生後主電網與配電網路之間的連接完全中斷，各微電網需以孤島模式完全依賴本地 DER 維持關鍵負載供電。主要系統假設如下：

- 主電網連接斷路：環境初始化時，將主電網的電源關閉，模擬災後主網失聯。
- 孤島運轉：系統內所有可控開關與 Tie-line 於初始狀態均為開路，由於 MG0-MG1 之間與 MG2-MG3-MG4 之間不設邊界開關，系統依物理連接自然形成兩個初始孤島，各孤島透過 Tie-line AND 投票機制決定是否相互連通。
- DER 配置：每個 MG 於最高負載 bus 部署 ESS 為 7.0 倍負載容量、0.8 倍負載功率與 PV 為 1.5 倍負載容量，另設 STATCOM 提供純虛功補償。
- Virtual Slack 指派：每個孤島內電量最充裕的 ESS 動態指派為虛擬參考節點，提供電壓與頻率基準。

上述 DER 配置之充裕性可從功率與能量兩個維度進行分析，說明跨 MG 協調的工程必要性。

- ◆ 功率維度分析：以夜間峰值負載係數為基準，單 MG 孤島下 ESS 額定功率具備 13.7% 的功率裕度，功率需求可獲滿足。然而，當多個 MG 合併為較大孤島時，虛擬 Slack ESS 需承擔合併後的整體功率平衡。以初始兩個孤島的最壞情境為例：

Island A (MG0 + MG1) 的 Slack 功率需求為 $0.956 \times P_{load}$ ，Island B (MG2 + MG3 +

MG4) 在非 Slack ESS 放電率 60%的條件下 Slack 需求仍達 $0.99 \times P_{load}$ ，均超出 0.8 倍的 ESS 額定功率。此結果說明，合併孤島情境下若缺乏非 Slack ESS 的協調放電，虛擬 Slack 將面臨超載，單憑額定功率設計無法滿足功率平衡需求。

- ◆ 能量維度分析：以 95%可用容量計算，ESS 可用儲能為 $6.65 \times P_{load}$ 。在無負載擾動條件下，以夜間平均負載係數計算，單 MG 的 ESS 可持續供電約 11.79 小時，對 12 小時夜間週期已呈 0.21 小時的能量赤字；當負載擾動達上限 ($\varepsilon=1.05$) 時，供電時間進一步縮短至 11.23 小時，赤字擴大至 0.77 小時。對於合併孤島情境，虛擬 Slack 承擔更高的功率輸出，ESS 以更快速率消耗，能量赤字將更為顯著。ESS 的額定功率規格設計及其與部署場景的對應關係，詳述於第四章系統配置說明。

功率與能量兩個維度的分析共同指出，各 MG 在合併孤島情境下無法獨立完成全日供電，跨 MG 協調放電是解決功率超載與能量赤字的工程必要條件，亦構成本研究多代理人協調設計的核心挑戰。

2.2 復電問題之數學模型與總體目標

2.2.1 系統架構與圖模型

配電系統之實體拓撲以圖論方式表示為 $G=(N,E)$ ，其中節點集合 N 對應電網匯流排，邊集合 E 代表支線連接關係。此圖結構描述系統的靜態連接關係，在復電過程中保持固定；然而，各節點與邊在不同時間步的運行狀態如是否通電、是否閉合會隨代理人的決策動態改變。本研究將 24 小時操作週期離散化為 $t=0,1,\dots,23$ 共 24 個時間步，並以狀態 s_t 描述圖 G 上所有節點與邊在時間步 t 的動態屬性集合。

在分散式 MARL 設定下，5 個代理人各管轄一個微電網區域，代理人間僅能透過由 Tie-line 構成的通訊圖進行 1-hop 鄰居資訊交換，整體系統不具備集中式的全局觀測能力。系統狀態 s_t 由下列維度組成：

- 節點供電狀態 $\delta_{i,t} \in \{0,1\}$ ：節點 i 是否成功獲得供電。
- 開關與 Tie-line 狀態 $u_{i,t} \in \{0,1\}$ ：支線 (i,j) 是否處於閉合連通狀態。
- ESS 電量狀態 $SOC_{k,t} \in [0\%,100\%]$ ：儲能設備 k 的當前電量比例。
- PV 預測出力 $\hat{P}_{i,t}^{pv}$ ：節點 i 的 PV 基礎預測出力，其不含隨機擾動。
- 節點電壓幅值 $V_{i,t} (p.u.)$ ：由上一時間步潮流計算結果取得。

上述資訊依代理人管轄範圍劃分，組構為各代理人的局部觀測向量。由於每個代理人僅能存取自身管轄範圍內的局部觀測，無法取得完整系統狀態，此資訊不完整性構成分散式部分可觀察馬爾可夫決策過程（Decentralized partially observable Markov decision process, Dec-POMDP）框架的核心部分可觀測性，詳述於第三章。

2.2.2 目標函數

關鍵負載復電（Critical Load Restoration, CLR）是配電系統韌性恢復的核心任務，旨在故障後透過最優的開關操作序列優先恢復醫院、通訊等重要設施的供電，以充分利用有限的 DER 資源。為將此目標納入強化學習的回饋設計，需建立能有效量化策略成效的目標函數，使代理人的策略優化方向與系統復電目標保持一致。

復電問題的核心目標為透過一系列具時序性之動作，最大化所有關鍵負載之供電能力。定義關鍵負載節點集合 C ，每一節點 c 具有重要性權重 ω_c 。系統之即時復電效益可表示為：

$$r_{crit} = \sum_{c \in C} \omega_c \cdot 1[bus\ c\ 已\ 供\ 電] \quad (2.1)$$

總體目標函數為最大化期望折扣累積獎勵：

$$\max E \left[\sum_{t=0}^{T-1} \gamma^t \cdot r_t \right] \quad (2.2)$$

其中折扣因子 $\gamma = 0.99$ ， $T=24$ 步對應災後 24 小時的復電操作時域。實際訓練所採用的複合獎勵函數為此目標的工程近似，詳見第四章獎勵函數設計。

2.3 動作空間

傳統配電網復電策略將開關決策形式化為整數變數，導致問題規模隨開關數量呈指數增長[7]；若對 ESS 連續功率進行粗糙離散化，量化精度不足將引入策略次優性，且動作維度隨量化細度指數爆炸[11]。本研究採用連續動作空間，以閾值解碼保留開關語義、以線性縮放實現 ESS 精確控制，在無需整數規劃的前提下支援梯度式策略學習

代理人 i 的動作向量包含兩類：

- (1) 連續型開關指令：對所管轄的每個 switch 輸出連續值 $x \in [-1, +1]$ ，以閾值解碼 $x > 0$ 閉合， $x \leq 0$ 斷開。針對跨 MG switch 與 Tie-line，需由兩端代理人同時投票閉合才能執行，此設計在 DTDE 框架下實現邊界開關的分散式協調。
- (2) 連續 ESS 調度指令：輸出充放電功率比例 $\alpha \in [-1, +1]$ ， $\alpha > 0$ 代表充電， $\alpha < 0$ 代表放電，依額定功率縮放為實際 MW 值

2.4 系統運作與物理約束條件

在配電網復電任務中，恢復供電能力的同時須確保系統不違反電氣安全邊界；若忽視這些約束，所設計的恢復策略將難以應用於實務，甚至可能導致電壓崩潰或設備損壞，引發二次故障並擴大停電範圍。本研究以 PandaPower 潮流計算作為每步的物理驗證器，代理人無需預先知曉約束的精確數學形式，而是透過各違規程度的懲罰分量間接感知可行域邊界，以資料驅動的方式學習符合電氣安全的操作策略。

代理人於每一時間步執行動作後，系統透過潮流分析驗證物理合規性，需遵循下列電氣約束：

- (1) 節點電壓限制：

節點電壓是衡量電網供電品質的核心指標之一。當節點電壓偏離額定值過大時，輕則影響用電設備的正常運作，重則可能引發電壓崩潰等系統性故障。本研究依據電力系統的一般工程規範，要求所有節點電壓幅值維持在額定值的 $\pm 5\%$ 容許範圍內：

$$0.95 p.u. \leq V_k \leq 1.05 p.u., \quad \forall k \in N \quad (2.3)$$

任何節點的電壓越限均視為操作違規，代理人將接收對應的懲罰信號。

(2) 支線容量限制：

電網支線的導體截面積與絕緣設計決定了其可承載的功率上限，長期超載運行會加速設備老化甚至引發跳脫保護動作。因此，每條支線的視在功率潮流必須控制在其額定容量之內：

$$P_e^2 + Q_e^2 \leq (S_e^{\max})^2 \quad (2.4)$$

一旦支線潮流超出額定上限，系統將依超載程度按比例回傳懲罰值，引導代理人學習避免產生過載操作。

(3) 供需平衡透過三層機制保障：

- i. 若孤島內所有 ESS 的 SOC 均低於 5%，該孤島於潮流計算前即強制停電。
- ii. 若潮流計算不收敛，系統回傳相應獎懲並凍結 SOC 更新。
- iii. 若潮流收敛後 Virtual Slack ESS 的剩餘電量不足以支撐當步輸出，系統強制將該孤島所有匯流排停電，模擬 ESS 耗盡所引發的供電崩潰。

上述約束的違反程度如何映射至具體懲罰分量，詳見第四章獎勵函數設計。

2.5 不確定性來源與部分可觀測性

分散式能源出力的不確定性是配電網復電策略設計面臨的核心挑戰之一，日照與風速等天候條件的隨機波動使得 DER 的瞬時供電能力難以準確掌握，顯著影響 DRL 方法的決策品質。在災後孤島化情境中，不確定性的來源亦不限於 DER 出力，負載需求因用電行為變化同樣存在預測偏差，而電力公司在實際運作中往往無法取得完整且準確的電網狀態資訊。Fan et al.[6]指出，相較於以強健優化或隨機規劃對 DER 出力進行補償，將不確定性轉化為環境的不可觀測狀態並以 POMDP 框架處理，更能反映代理人在決策時面對的真實資訊限制。

PV 之即時出力受天候影響，代理人僅能觀測預測出力 $\hat{P}_{pv,t}$ ，其實際出力帶有隱藏

的隨機擾動：

$$P_{pv,t}^{actual} = \hat{P}_{pv,t} \times \varepsilon_t, \quad \varepsilon_t \sim Uniform(0.95, 1.05) \quad (2.5)$$

擾動係數 ε_t 在每個時間步獨立取樣且不對代理人揭露，構成系統環境的內在隨機性。

此隨機性與局部觀測限制共同決定了本研究問題的 POMDP 特性：前者描述環境的不確定性，即代理人即使採取相同動作，結果仍有變異，後者描述觀測的不完整性，即代理人無法取得完整系統狀態。

第三章 強化學習模型設計

本研究所處理的微電網災後關鍵負載復電問題，在數學上具有以下幾個典型特徵：決策空間為高維連續空間，如 ESS 充放電功率、switch 與 Tie-line 投切建議；環境狀態僅能被局部觀測，即各微電網代理人僅知悉自身管轄區域與部分鄰居的資訊；決策效果具有跨時間步的累積性，意即 ESS 電量狀態隨充放電操作逐步演變，當前時間步的能量調度決策將直接影響後續時間步的可用電量；以及多個代理人同時在共享物理基礎設施上進行協調控制。上述特徵的組合，使得本問題不能簡單的套用傳統的數學規劃方法或基於離散動作空間的深度強化學習框架，而需要從強化學習理論出發，逐層建構適合本研究特性的模型架構。

本章依照理論演進的邏輯脈絡，依序介紹本研究所採用的各項核心技術。第 3.1 節從馬可夫決策過程出發，沿理論演進脈絡逐步延伸至部分可觀測馬可夫決策過程與分散式部分可觀測馬可夫決策過程，最終確立本研究的正式決策建模框架；第 3.2 節介紹多代理人強化學習的主流訓練架構，比較集中式訓練分散式執行與分散式訓練分散式執行之特性，並說明本研究採用後者的理由；第 3.3 節沿著策略梯度方法的演進脈絡，依序介紹確定性策略梯度、深度確定性策略梯度，以及本研究採用的雙延遲深度確定性策略梯度之三大穩定化機制；第 3.4 節介紹 LSTM 與 GRU 兩種時序記憶模型的基本原理，並從架構特性說明選型依據；第 3.5 節介紹圖神經網路的理論基礎與本研究的加權局部聚合設計；第 3.6 節說明策略共識機制；第 3.7 節介紹雙池經驗回放記憶架構的設計原理。

3.1 決策過程框架

本研究所面對的復電問題涉及多代理人、部分可觀測與分散式決策等複合特性，無法直接套用單一的標準決策框架。本節從最基礎的馬可夫決策過程出發，依序說明各框架的假設要求，並逐步延伸至最終採用的 Dec-POMDP 框架，闡明每一步延伸背後的問題驅動。

3.1.1 馬可夫決策過程 (Markov Decision Process, MDP)

馬可夫決策過程 (Markov Decision Process, MDP) 是強化學習的數學基礎框架，由 Bellman 於 1957 年奠定基本形式，後由 Sutton 與 Barto 系統化融入現代強化學習體系[5]。MDP 的核心假設為馬可夫性質：系統下一狀態的轉移機率僅取決於當前狀態 s_t 與動作 a_t ，與歷史序列無關。一個 MDP 正式定義為五元組： $MDP = (S, A, P, R, \gamma)$

其中 S 為狀態空間， A 為動作空間， $P(s'|s, a)$ 為狀態轉移機率函數， $R(s, a)$ 為即時獎勵函數， $\gamma \in (0, 1)$ 為折扣因子。代理人的目標是學習策略 $\pi: S \rightarrow A$ 以最大化期望累積折扣獎勵，最優動作價值函數 $Q^*(s, a)$ 滿足 Bellman 最優方程：

$$Q^*(s, a) = R(s, a) + \gamma \sum_{s'} P(s'|s, a) \cdot \max_{a'} Q^*(s', a') \quad (3.1)$$

然而，MDP 要求代理人能於每一時間步完整觀測真實狀態。在本研究的微電網孤島化情境中，此假設存在四個根本性違反：

- 一、各微電網代理人僅能觀測其管轄區域的局部電氣量測值
 - 二、再生能源出力的實際值在決策時未知，代理人僅能獲得帶預測誤差的估計值
 - 三、Virtual Slack 節點依 ESS 電量狀態自動指派，代理人無法觀測鄰近微電網的指派情形，亦無法預判後續切換位置
 - 四、在 DTDE 架構下，代理人 i 無法觀測代理人 j 同步採取的動作。
- 前三項促使採用 POMDP 延伸框架，第四項則進一步要求推廣至 Dec-POMDP，依序詳述於以下兩節。

3.1.2 部分可觀測馬可夫決策過程 (POMDP)

部分可觀測馬可夫決策過程 (Partially Observable Markov Decision Process, POMDP) 在保留 MDP 馬可夫轉移假設的基礎上，放寬了完全可觀測性假設，允許代理人僅能獲得真實狀態的部分間接觀測[5]。POMDP 正式定義為七元組：

$$POMDP = (S, A, P, R, \Omega, O, \gamma) \quad (3.2)$$

相較於 MDP，新增觀測空間 Ω 與觀測機率函數 $O(o|s', a)$ ，後者定義執行動作 a 並轉移至狀態 s' 後，代理人接收到觀測值 o 的條件機率。由於代理人無法直接存取真實狀態，最優策略須以信念狀態（Belief State） $b_t(s) = P(s_t = s | o_{1:t}, a_{1:t-1})$ 為輸入，並透過貝葉斯規則遞迴更新：

$$b_{t+1}(s') = \eta \cdot O(o_{t+1}|s', a_t) \cdot \sum_s P(s'|s, a_t) \cdot b_t(s) \quad (3.3)$$

精確信念更新需對所有可能狀態進行積分，在大規模連續狀態空間中此積分在數學上即無法精確求解，實務上以循環神經網路的隱藏狀態 h_t 隱式近似信念狀態—由於 h_t 由觀測與動作序列 $(o_1, a_1, \dots, o_t)$ 遞迴計算而得，與信念狀態 b_t 所依賴的資訊基礎一致，因此 h_t 可作為 b_t 的函數近似，本研究採用 GRU 實現此近似，選型依據詳見第 3.4 節。然而，POMDP 僅適用於單一代理人場景；當系統涉及多個分散式決策代理人且各自面臨局部觀測限制時，需進一步推廣至 Dec-POMDP，詳述於下節。

3.1.3 分散式部分可觀測馬可夫決策過程（Dec-POMDP）

分散式部分可觀測馬可夫決策過程（Decentralized Partially Observable Markov Decision Process, Dec-POMDP）由 Bernstein et al. 於 2002 年正式定義並分析其計算複雜性[13]，是協作型多代理人決策問題在部分可觀測條件下的形式化框架。Dec-POMDP 正式定義為八元組：

$$Dec-POMDP = \langle I, S, A, P, R, \Omega, O, \gamma \rangle \quad (3.4)$$

本研究採用折扣報酬形式，以折扣因子 γ 取代原始定義中的有限時域 T 與門檻值 K ，符合深度強化學習的標準表達慣例。相較於 POMDP，Dec-POMDP 在多代理人場景下擴充了以下元素： $I = \{1, \dots, N\}$ 為代理人集合；聯合觀測空間 $\Omega = \prod_i \Omega^i$ ，其中 Ω^i 為代理人 i 的局部觀測空間；聯合觀測函數 $O(o^1, \dots, o^N | s', a)$ 定義系統執行聯合動作 a

並轉移至狀態 s' 後，各代理人分別接收各自局部觀測的聯合條件機率；全域獎勵函數 $R(s, a)$ 由所有代理人共享，體現完全合作的系統目標。

Dec-POMDP 與 POMDP 的核心差異在於：POMDP 為單一代理人框架，代理人的部分可觀測性源於感測器限制或資訊隱藏；Dec-POMDP 為多代理人框架，部分可觀測性同時來自局部感測限制以及代理人間的動作不可見性，意即代理人 i 在時間 t 無法觀測代理人 j 同步採取的動作 a_j^t ，此特性在分散式執行中不可避免。Dec-POMDP 的求解目標是尋找最優聯合策略 $\pi^* = (\pi^{1*}, \dots, \pi^{N*})$ ，其中各代理人策略 π^i 僅以本地局部觀測歷史 $\tau_t^i = (o_1^i, a_1^i, \dots, o_t^i)$ 為輸入，在不依賴全局資訊的條件下最大化全體代理人的期望累積折扣獎勵。

3.1.3.1 框架選用說明

本研究採用 Dec-POMDP 作為問題的正式建模框架，而非單代理人 POMDP，理由如下：

- 一、系統包含 5 個微電網代理人，本質上為多代理人問題，單代理人 POMDP 無法刻劃代理人間的互動動態
- 二、部分可觀測性來源涵蓋局部量測限制、再生能源出力不確定性及代理人動作不可見性三個面向，三者均為 Dec-POMDP 的固有特徵
- 三、本研究採用 DTDE 架構，代理人在訓練與執行階段均不依賴全局資訊，與 Dec-POMDP 分散式決策的本質一致。

然而，嚴格的 Dec-POMDP 定義要求全域獎勵函數 $R(s, a)$ 以完整系統狀態 s 計算並由所有代理人共享，此要求在 DTDE 框架下無法直接滿足，其代理人於訓練與執行階段均無法存取全域狀態。針對此約束，本研究將全域目標分解為各代理人可局部計算的近似獎勵 r_i ，其設計包含兩個層次：個體項反映代理人自身管轄區域的復電比例、電壓品質與 ESS 能量管理等局部目標；協作項則以整體復電比例 R / R_{total} 為基礎計

算跨 MG 合作加成，在不依賴全域狀態的前提下傳遞系統層級的協調信號。此設計確保各代理人的個體優化方向與系統整體復電目標保持一致，從而在分散式計算約束下保留 Dec-POMDP 完全合作框架的實質意涵。

3.1.3.2 本研究之 Dec-POMDP 模型定義

本研究將 IEEE 123-bus 微電網關鍵負載復電問題正式建模為 Dec-POMDP，以下逐一說明各元素在本研究中的具體對應。

- 代理人集合 I ：對應電網劃分所得之五個微電網 MG0-MG4，各代理人獨立運行並僅能感知其管轄區域的局部資訊。
- 真實狀態空間 S ：包含整個 IEEE 123-bus 電網於任一時間步 t 的完整物理狀態，向量 s_t 涵蓋：全部 130 條匯流排的電壓幅值 $V_t \in \mathbb{R}^{130}$ 、所有 switch 與 Tie-line 的開關狀態 $u_t \in \{0,1\}^{|sw|}$ 、各 ESS 的電量狀態 $SOC_t \in \mathbb{R}^{n_{ess}}$ 、PV 經擾動後的實際出力，為含 $\pm 5\%$ 均勻擾動的真實值、STATCOM 的虛功補償量，以及三個關鍵負載的即時供電狀態。上述完整狀態向量僅由系統環境內部維護，代理人無法直接存取。
- 聯合動作空間 $A = \prod_{i \in I} A^i$ ：代理人 i 的局部動作作為連續向量：

$$a_{i,t} = \left[x_{i,1}^{sw}, \dots, x_{i,n_i^{sw}}^{sw}, a_{i,1}^{ess}, \dots, a_{i,n_i^{ess}}^{ess} \right] \in [-1, +1]^{d_i} \quad (3.5)$$

前段為各開關的投切控制量，並以符號判斷開合，後段為各 ESS 的充放電功率控制量。跨 MG 的 Tie-line 需兩端代理人均輸出正值的 AND 投票方可實際閉合，此機制隱含了代理人間的隱式協調需求。

- 狀態轉移函數 $P(s'|s,a)$ ：在聯合動作 a 執行後，系統根據電力物理方程求解新的電氣平衡狀態，並疊加每步 $\pm 5\%$ 的 PV 均勻擾動，使狀態轉移包含不可消除的隨機成分。
- 聯合觀測空間 $\Omega = \prod_{i \in I} \Omega^i$ ：代理人 i 的局部觀測向量 $o_{i,t} \in \Omega^i$ 僅包含 MG_i 管轄範圍內的資訊，具體結構包含：每個匯流排的電壓偏差、負載功率、PV 基礎預測出力

且不含實際擾動量、ESS 電量狀態、開關狀態與線路潮流，以及來自通訊鄰居的平均 SOC 資訊。

- 觀測函數 $O(o^i | s', a)$ ：給定系統狀態 s' ，代理人 i 的觀測值由其管轄區域的物理量直接決定，不含額外觀測噪聲。觀測的不確定性來源在於 PV 預測誤差：代理人觀測到的是基礎預測值，而非擾動後的真實出力，形成結構性觀測偏差。
- 獎勵函數 $R(s, a)$ ：採用協作型設計，各代理人的局部獎勵 $r_{i,t}$ 包含反映個體目標的通電比例、關鍵負載復電量，以及反映整體協作的跨 MG 整體恢復獎勵，共 15 項加權組合，詳細設計與各項權重係數詳見第 4.4.6 節。雖然獎勵以局部形式計算，但整體恢復獎勵項確保各代理人的優化方向與系統整體目標一致，實現完全合作設定的實質效果。
- 折扣因子 γ ：本研究設定 $\gamma=0.99$ ，強調對整個 24 小時復電週期的長期規劃能力，確保代理人不因短期獎勵而忽視後期的電網穩定需求。

3.2 多代理人強化學習訓練架構

多代理人強化學習中，各代理人在同步更新策略的過程中，環境從任一代理人的視角持續變化，形成非穩態問題（Non-stationarity），使單代理人強化學習的收斂假設失效。為此，學術界依據訓練與執行兩個階段對資訊的存取範圍，發展出兩類主流訓練架構。

3.2.1 集中式訓練分散式執行（CTDE）

集中式訓練分散式執行（CTDE）的核心思想是在訓練與執行之間允許資訊的非對稱性：訓練階段設立集中式 Critic，可存取所有代理人的觀測與動作以估計全局價值函數；執行階段各代理人策略僅依賴本地觀測獨立決策。此非對稱設計的關鍵優勢在於：Critic 在訓練時掌握其他代理人的同步動作，使多代理人環境從 Critic 的視角恢復穩態，有效緩解非穩態問題並提供更準確的梯度估計。然而，CTDE 的根本限制在於

訓練階段必須存取所有代理人的全局資訊，對集中式或全連接通訊的依賴隨代理人數量增加而加劇，在通訊受限、隱私敏感或代理人數量動態變化的實際場景中可行性不足。

3.2.2 分散式訓練分散式執行 (DTDE)

分散式訓練分散式執行 (DTDE) 在訓練與執行兩個階段均不依賴全局資訊，各代理人僅以本地觀測及有限的鄰居通訊為輸入，獨立維護並更新各自的策略網路與 Critic 網路。此架構消除了對集中式通訊通道的依賴，在擴展性、隱私保護與通訊強健性方面具有天然優勢。代價是各代理人的 Critic 僅以局部資訊估計價值函數，非穩態問題更難克服，收斂穩定性隨代理人規模增大而下降，且在代理人規模增大時收斂穩定性下降。引入鄰居資訊共享與週期性參數共識是改善 DTDE 非穩態問題的常見方案，其核心思想是在不要求全局通訊的前提下，透過局部協調使各代理人的策略逐步趨近一致。

3.2.3 本研究採用 DTDE 之理由

本研究採用 DTDE 訓練架構，理由如下：真實配電系統中各微電網由不同實體管轄，內部運營資料不對外共享，孤島化復電場景下通訊基礎設施本身亦可能受損，CTDE 所需的全局通訊通道在實際部署中難以保證；其次，DTDE 各代理人網路規模不受系統整體規模影響，具備更佳的可擴展性；此外，對全局通訊的零依賴性使系統在局部通訊中斷時仍能維持自主決策能力，符合電力系統孤島化復電的強健性需求。針對 DTDE 固有的非穩態問題，本研究引入雙重參數共識機制，詳見第 3.6 節。

3.3 策略梯度方法與 Actor-Critic 演進

在強化學習演算法中，按照策略表示方式可分為基於值函數的方法 (Value-based) 與策略梯度方法 (Policy Gradient) 兩大類別。基於值函數的方法如 Q-Learning

及其深度擴展 DQN 透過學習動作價值函數 $Q(s, a)$ 間接推導策略，在離散動作空間中表現出色；然而面對連續動作空間時，此類方法需對動作空間進行人為離散化，不僅引入量化誤差，且隨動作維度增加，離散化後的組合空間呈指數級爆炸，實用性迅速降低。

策略梯度方法直接對策略函數進行參數化，以神經網路輸出動作，透過梯度上升最大化期望累積獎勵，天然適用於連續動作空間。本研究所面對的微電網控制問題中，各代理人需同時控制 ESS 充放電功率與開關投切，兩類控制統一以連續動作向量表示。連續動作的優勢在於其數值大小與符號可同時編碼控制量的方向與強度，使開關投切（由符號判斷開合）[6]與功率控制（由數值大小決定出力）得以在同一策略網路中一致性地學習；ESS 出力的精確數值直接影響潮流計算結果與電壓合規性，不允許粗糙的離散化近似。因此，策略梯度方法是本研究採用的技術路線。

在策略梯度方法的發展中，Actor-Critic 架構是克服純策略梯度方法效率瓶頸的關鍵突破。純策略梯度方法如 REINFORCE 以蒙地卡羅回報估計策略梯度，雖然無偏但方差極高，導致訓練效率低落[5]。Actor-Critic 架構引入兩個相互配合的神經網路：Actor 負責參數化策略並輸出動作，Critic 負責估計狀態或動作的價值函數，以學習到的估計值取代高方差的蒙地卡羅回報，為 Actor 的梯度計算提供低方差的評估信號。此設計在降低方差的同時保留了策略梯度對連續動作空間的適用性，顯著提升訓練的樣本效率與收斂穩定性。

在 Actor-Critic 架構的基礎上，Actor 的策略表示方式可進一步分為兩類：隨機策略將動作建模為機率分布如 Gaussian，適用於需要主動探索的環境；確定性策略則直接輸出具體動作值，省去取樣步驟，在連續動作空間中具備更高的計算效率。本研究所採用的確定性策略梯度（DPG）、深度確定性策略梯度（DDPG）至雙延遲深度確定性策略梯度（TD3）形成了一條清晰的演進路線，每一步針對前者的特定限制提出改進，正是基於確定性策略的 Actor-Critic 發展，是本研究所採用演算法的核心發展脈絡，依序詳述於以下各節。

3.3.1 確定性策略梯度 (Deterministic Policy Gradient, DPG)

Silver 等人於 2014 年提出確定性策略梯度 (Deterministic Policy Gradient, DPG) 定理，為在連續動作空間中高效學習確定性策略奠定了理論基礎[10]。

傳統隨機策略梯度定理 (Stochastic Policy Gradient) 在估計策略梯度時，需對整個動作機率分佈進行積分，計算量隨動作維度的增加而顯著上升；在高維連續動作空間中，此積分的蒙地卡羅估計具有較高的方差，降低了學習效率。DPG 定理則指出，確定性策略 μ_θ 的性能梯度僅需在當前策略所輸出的單一動作點處進行評估，無需對整個動作空間積分，大幅降低了梯度估計的計算代價。DPG 定理的數學形式為：

$$\nabla_\theta J(\mu_\theta) = E_{s \sim \rho^\mu} \left[\nabla_a Q^\mu(s, a) \Big|_{a=\mu_\theta(s)} \cdot \nabla_\theta \mu_\theta(s) \right] \quad (3.6)$$

其中 $J(\mu_\theta)$ 為策略性能度量，即為期望累積折扣獎勵， ρ^μ 為遵循確定性策略 μ 所誘導的折扣狀態訪問頻率分佈。梯度由兩部分透過鏈式法則相乘組成： $\nabla_a Q^\mu(s, a) \Big|_{a=\mu_\theta(s)}$ 為 Q 值在當前策略動作處對動作維度的梯度，由 Critic 網路估計； $\nabla_\theta \mu_\theta(s)$ 為策略網路輸出對參數的梯度，由 Actor 網路計算。此設計使策略改進問題得以轉化為：沿 Q 函數在動作維度上的梯度方向更新策略參數，整個 Actor-Critic 框架可進行端到端的梯度訓練。

DPG 採用離線策略 (off-policy) 學習架構，以帶有探索噪聲的行為策略採集環境轉移樣本，並以確定性目標策略進行梯度更新，理論上具備搭配經驗回放記憶機制提升資料效率的基礎。然而，原始 DPG 以線性函數逼近 Critic，限制了其在高維非線性問題中的表達能力，且未系統性地整合深度神經網路與穩定化訓練機制。後續研究在 DPG 的理論框架上，引入深度神經網路、經驗回放與目標網路，發展出深度確定性策略梯度 (DDPG) 演算法，正式將 off-policy 的資料效率優勢落實於高維連續控制任務，詳述於下節。

3.3.2 深度確定性策略梯度 (Deep Deterministic Policy Gradient,

DDPG)

Lillicrap 等人於 2016 年提出深度確定性策略梯度 (DDPG)，以深度神經網路實現 DPG 的 Actor-Critic 框架，並引入經驗回放與軟更新目標網路兩項工程機制，構成完整的四網路訓練架構：主 Actor μ_θ 、主 Critic Q_ϕ 、目標 Actor $\mu_{\theta'}$ 、目標 Critic $Q_{\phi'}$ ，DDPG 機制架構如圖 3.1，使確定性策略梯度方法得以在高維連續控制問題上穩定訓練[11]。

- **經驗回放 (Experience Replay)**：代理人與環境互動所產生的每一條轉移樣本 $(s_t, a_t, r_t, s_{t+1}, done_t)$ 依序存入回放緩衝區 D ，在每次參數更新時均勻隨機抽取大小為 B 的 mini-batch 進行梯度計算。此機制源自 DQN，具備兩項核心優勢：其一，隨機取樣打破相鄰時間步之間的時間相關性，消除連續時序樣本對梯度估計造成的偏差；其二，緩衝區中每筆樣本可被多次抽取用於參數更新，顯著提升資料使用效率[14]。
- **軟更新目標網路 (Soft-Update Target Network)**：DDPG 採用 DQN 的目標網路概念，但將 DQN 的週期性硬更新直接複製參數改良為軟更新，以小步長 $\tau \ll 1$ 持續緩慢同步目標網路參數，此為 Lillicrap et al. (2016) 的重要創新之一：

$$\theta' \leftarrow \tau\theta + (1-\tau)\theta', \quad \phi' \leftarrow \tau\phi + (1-\tau)\phi' \quad (3.7)$$

目標網路的作用在於提供相對穩定的 TD 訓練目標，避免 Critic 在訓練過程中因目標值頻繁變動而發散。Critic 的 TD 目標值定義為：

$$y_t = r_t + \gamma(1 - done_t) \cdot Q_{\phi'}(s_{t+1}, \mu_{\theta'}(s_{t+1})) \quad (3.8)$$

Critic 以最小化均方誤差損失進行更新：

$$\min_{\phi} E \left[\left(Q_{\phi}(s_t, a_t) - y_t \right)^2 \right] \quad (3.9)$$

Actor 遵循式 (3.6) 的確定性策略梯度定理，以 Critic 提供的 Q 值梯度驅動策略改進。

- **探索噪聲 (Exploration Noise)**：確定性策略本身不具備探索能力，DDPG 原始論

文採用 Ornstein-Uhlenbeck (OU) 過程作為探索噪聲，其均值回歸特性使連續時間步的動作具有一定慣性，適合對動作平滑性有要求的機械控制問題；後續研究則普遍改用計算更簡便的高斯噪聲 $N(0, \sigma^2)$ ，以行為策略 $a_t = \mu_\theta(s_t) + N$ 與環境互動，確保訓練樣本的多樣性。

儘管 DDPG 相較於 DPG 取得了顯著進步，Fujimoto 等人系統性地指出其在實際應用中仍存在兩項核心問題[12]：其一，函數逼近誤差在 Actor-Critic 交互更新過程中導致 Q 值持續性高估，即便有目標網路的緩解仍難以避免；其二，Q 函數網路在某些動作處容易產生不準確的尖銳偏差，Actor 傾向過度利用這些偏差，最終導致策略脆弱而不穩定。這兩項限制直接促使 TD3 架構的提出，詳述於下節。




圖 3.1 DDPG 機制架構

3.3.3 雙延遲深度確定性策略梯度 (TD3)

Fujimoto 等人於 2018 年提出 TD3，針對 DDPG 在實際應用中的三項已知限制——Q 值持續性高估、Actor-Critic 耦合更新不穩定，以及策略對 Q 函數估計誤差的過度利用——各自設計了對應的改進機制[12]。TD3 已成為連續動作空間深度強化學習的重要基準方法，在 MuJoCo 物理模擬控制任務上取得了相較於 DDPG 的一致性能提升。本研究以 TD3 作為各微電網代理人的核心學習演算法，三項機制分述如下：

一、截斷雙 Critic 網路 (Clipped Double Q-Learning)

在 Actor-Critic 架構中，Actor 被訓練以最大化 Critic 所估計的 Q 值，因此系統性的傾向選擇 Q 網路估計值偏高的動作，形成選擇偏差；加上 TD 自舉更新使誤差在訓練過程中持續累積，最終導致 Q 值系統性高估。此問題類似於 Q-learning 中 max 算子所引入的最大化偏差，Van Hasselt 等人提出的 Double DQN 以分離動作選擇與值估計的方式加以緩解[15]。TD3 將此思想發展為截斷雙 Critic 機制：同時維護兩組獨立的 Critic 網路 Q_{ϕ_1} 與 Q_{ϕ_2} ，各自具有獨立的目標網路 $Q_{\phi_1'}$ 與 $Q_{\phi_2'}$ ，計算 TD 目標值時取兩組估計的較小值：

$$y = r + \gamma(1 - done) \cdot \min_{j=1,2} Q_{\phi_j'}(s', \tilde{a}') \quad (3.10)$$

此悲觀估計策略雖引入一定程度的低估傾向，但相較於無約束的系統性高估，低估的策略可透過進一步探索加以修正，而持續高估則會引導代理人反覆執行被誤估的動作，造成難以逆轉的策略退化。兩組 Critic 網路均以相同的 TD 目標值 y 進行訓練，損失函數定義為：

$$L_{\phi} = E_B \left[L_H(Q_{\phi_1}(s, a) - y) + L_H(Q_{\phi_2}(s, a) - y) \right] \quad (3.11)$$

其中 L_H 為 Smooth L1 損失函數，相較於均方誤差對訓練過程中的離群估計值更具強健性，本研究以 Smooth L1 Loss 取代原版 TD3 的 MSE，其對大誤差退化為線性懲罰的特性，可有效抑制電網潮流不收斂時零獎勵回傳所造成的異常 Bellman 誤差。

二、延遲策略更新 (Delayed Policy Update)

DDPG 訓練不穩定的另一來源是 Critic 與 Actor 的耦合更新問題：Critic 的 Q 值估計誤差透過策略梯度立即影響 Actor 的更新方向，而更新後的 Actor 又產生新的訓練樣本進一步影響 Critic，形成惡性循環。TD3 採用延遲策略更新機制，設定每更新 Critic 兩次才更新 Actor 一次。此設計確保 Critic 的 Q 值估計在 Actor 更新前已充分收斂，使策略梯度方向具有更高的可靠性，從而顯著降低策略更新的累積誤差。Actor 的更新目標為最大化 Critic 1 的 Q 值估計：

$$L_{\theta} = -E_B \left[Q_{\phi} \left(s, \mu_{\theta}(s) \right) \right] \quad (3.12)$$

Actor 更新完成後，同步以軟更新方式同步所有目標網路參數。

三、目標策略平滑化 (Target Policy Smoothing)

Q 函數網路在訓練過程中可能對某些動作產生不準確的尖銳估計峰值，Actor 的策略梯度指向 Q 值上升方向，因此傾向過度利用這些估計峰值，持續輸出對應動作，即使該動作在真實環境中的效益未必最高，最終導致策略脆弱而不穩定。TD3 通過在計算 TD 目標值時，對目標策略輸出的動作加入截斷高斯噪聲，對 Q 函數施加局部平滑正則化：

$$\tilde{a}' = \text{clip} \left(\mu_{\theta'}(s') + \text{clip}(\varepsilon, -c, +c), a_{\text{low}}, a_{\text{high}} \right), \quad \varepsilon \sim N(0, \sigma^2) \quad (3.13)$$

其中 σ 為噪聲標準差， c 為截斷範圍，均為可調超參數。此設計要求 Critic 在目標動作 $\tilde{a}'$ 鄰域內的 Q 值預測保持一致性，從而抹平局部的尖銳估計峰值，降低 Actor 陷入 Critic 高估局部極值的風險。

TD3 整體架構如圖 3.2，三項機制的協同作用使 TD3 在訓練穩定性與策略品質上均顯著優於 DDPG，本研究因此採用 TD3 作為各微電網代理人的核心學習演算法。




圖 3.2 TD3 機制架構

3.4 時序記憶模型

微電網災後復電過程的決策問題在時間維度上具有高度的依賴性，這一特性可從以下三個方面加以說明。

一、ESS 的電量狀態（State of Charge, SOC）隨充放電操作的累積效應持續演變，當前時間步的充電決策直接影響後續時間步的可用電量，代理人必須進行跨時間步的能量管理規劃，而非僅優化當步效益。

二、跨 MG 開關的投切狀態由多代理人協同決策共同決定，各時間步的投切選擇累積形成當前的區塊劃分結構，進而決定各微電網的潮流分佈與後續可行動作空間。代理人若無法記憶歷史投切序列，便難以準確推斷當前網路拓撲狀態。

三、在部分可觀測馬可夫決策過程（Partially Observable Markov Decision Process, POMDP）框架下，單一時間步的局部觀測所含資訊量有限，代理人需整合歷史觀測序列中的時序資訊，以重建對環境隱藏狀態的準確推斷。

上述三類依賴性共同說明，孤立的單步觀測不足以支撐有效決策，代理人需具備跨時間步的記憶能力。

靜態前饋神經網路（Feedforward Neural Network）在每次推論時僅以當前輸入計算輸出，不保留任何歷史資訊，因此無法對序列資料的跨時間依賴關係進行建模，無法無限期保留過去輸入的資訊[16]。循環神經網路（Recurrent Neural Network, RNN）藉由引入隱狀態作為記憶機制，得以對任意長度的輸入序列進行建模；然而，以時序反向傳播（Backpropagation Through Time, BPTT）訓練 RNN 時，誤差訊號隨時間的演變呈指數依賴於權重大小，導致梯度消失（Vanishing Gradient）或梯度爆炸

（Exploding Gradient），使學習跨越長時間間隔的依賴關係需耗費極長時間，乃至完全失敗[17]。針對此問題，Hochreiter & Schmidhuber 提出長短期記憶網路（Long Short-Term Memory, LSTM），透過引入乘法式輸入閘門與輸出閘門，分別控制資訊寫入與讀取的時機，從而在記憶胞內部實現常數誤差流，使網路得以有效橋接長程時序依賴。

Cho et al. 進一步提出門控循環單元（Gated Recurrent Unit, GRU），以重置閘門（Reset

Gate) 與更新閘門 (Update Gate) 兩個門控單元簡化 LSTM 的閘門結構，在保留長程記憶能力的同時降低計算複雜度[18]；每個隱藏單元具備獨立門控，可自適應地捕捉不同時間尺度的依賴關係。本節分別介紹 LSTM 與 GRU 的基本原理；兩者在本研究情境下的適用性比較，將於 3.4.3 節進一步討論。

3.4.1 長短期記憶網路 (LSTM)

長短期記憶網路 (Long Short-Term Memory, LSTM) 設計目標在於解決循環神經網路以梯度下降學習長程依賴時的根本困難，整體架構如圖 3.3。傳統 RNN 在以時序反向傳播訓練時，誤差訊號的縮放因子隨時間步數增加而指數衰減，導致早期時間步的梯度幾乎消失，使網路無法有效學習跨越長時間間隔的時序依賴關係。

LSTM 的核心創新在於引入顯式的記憶單元 (Cell State) c_t 作為資訊的長期儲存通道。記憶單元的更新採用線性加法結構，使誤差訊號得以在記憶胞內部以近似常數的形式流動，有效緩解梯度消失問題。為精細控制記憶單元中資訊的寫入與讀取，LSTM 引入三個可學習的閘控機制，分別為遺忘閘、輸入閘與輸出閘。

遺忘閘 (Forget Gate) 負責決定前一記憶狀態 c_{t-1} 中哪些資訊應予以捨棄，其輸出為介於 (0,1) 之間的遺忘係數：

$$f_t = \sigma(W_f \cdot [h_{t-1}, x_t] + b_f) \quad (3.14)$$

輸入閘 (Input Gate) 控制當前輸入所攜帶的新資訊中哪些應被寫入記憶單元，並配合候選記憶 $\tilde{c}_t$ 共同決定寫入的內容：

$$i_t = \sigma(W_i \cdot [h_{t-1}, x_t] + b_i) \quad (3.15)$$

$$\tilde{c}_t = \tanh(W_c \cdot [h_{t-1}, x_t] + b_c) \quad (3.16)$$

記憶單元的更新透過遺忘閘與輸入閘的協同作用，實現選擇性遺忘舊資訊與選擇性寫入新資訊的精細記憶管理：

$$c_t = f_t \odot c_{t-1} + i_t \odot \tilde{c}_t \quad (3.17)$$

輸出閘 (Output Gate) 根據記憶單元的當前內容，決定向外輸出的隱藏狀態 h_t ：

$$o_t = \sigma(W_o \cdot [h_{t-1}, x_t] + b_o) \quad (3.18)$$

$$h_t = o_t \odot \tanh(c_t) \quad (3.19)$$

其中 $\sigma(\cdot)$ 為 Sigmoid 激活函數， $\odot$ 為逐元素乘積， W 與 b 分別為各閥的可學習權重矩陣與偏置向量。上述閥控機制使 LSTM 能夠在任意長度的序列中，自適應地保留或捨棄不同時間步的資訊，從而在需要長程記憶的決策任務中展現出顯著優勢[17]。




圖 3.3 LSTM 模組架構圖

3.4.2 門控循環單元 (GRU)

門控循環單元 (Gated Recurrent Unit, GRU) 由 Cho 等人於 2014 年提出，以 LSTM 為設計動機，透過簡化閥門結構降低計算複雜度，同時保留處理長程時序依賴的核心能力[18]，整體架構如圖 3.4。GRU 的結構簡化主要體現在兩個方面：其一，將 LSTM 的遺忘閥與輸入閥合併為單一的更新閥，由更新閥同時決定保留舊資訊與納入新資訊的比例；其二，取消獨立的記憶單元，直接以隱藏狀態 h_t 統一承擔長短期記憶功能。

重置閥 (Reset Gate) 控制前一隱藏狀態 h_{t-1} 在生成候選狀態時的參與程度：重置閥趨近 0 時，候選狀態幾乎只由當前輸入決定，相當於忽略歷史資訊；趨近 1 時，歷史資訊充分參與候選狀態的生成：

$$r_t = \sigma(W_r \cdot [h_{t-1}, x_t] + b_r) \quad (3.20)$$

更新閥 (Update Gate) 同時承擔 LSTM 遺忘閥與輸入閥的雙重功能，決定隱藏狀

態中舊資訊與新候選資訊的混合比例：

$$z_t = \sigma(W_z \cdot [h_{t-1}, x_t] + b_z) \quad (3.21)$$

候選隱藏狀態由重置閘過濾後的歷史隱狀態與當前輸入共同生成：

$$\tilde{h}_t = \tanh(W_h \cdot [r_t \odot h_{t-1}, x_t] + b_h) \quad (3.22)$$

最終的隱藏狀態更新為舊狀態與候選狀態的線性插值：

$$h_t = z_t \odot h_{t-1} + (1 - z_t) \odot \tilde{h}_t \quad (3.23)$$

當更新閘 z_t 趨近 1 時，幾乎完全保留前一隱藏狀態，模擬長期記憶維持的行為；趨近 0 時，幾乎完全替換為候選狀態，模擬快速適應新資訊的行為。其中 $\sigma(\cdot)$ 為 Sigmoid 激活函數， $\odot$ 為逐元素乘積， W 與 b 分別為各閘的可學習權重矩陣與偏置向量。此機制使 GRU 在面對不同時間尺度的依賴關係時，能夠自適應地調整記憶更新速率，每個隱藏單元可獨立學習捕捉短程或長程的時序特徵。




圖 3.4 GRU 模組架構圖

3.4.3 LSTM 與 GRU 比較與選用分析

LSTM 過分離記憶單元與隱藏狀態，對資訊的寫入與讀取實施更精細的獨立控制，理論上具備更強的長程記憶能力；然而，分離的雙狀態結構（隱藏狀態 h_t 與記憶單元 c_t ）使得每步需傳遞兩倍維度的狀態向量，且四組權重矩陣帶來較高的參數量，在多代理人並行訓練的情境下對記憶體與計算資源的需求更為顯著。

相對地，GRU 以統一的隱藏狀態 h_t 承擔記憶功能，更新閘的線性插值結構在保留解決梯度消失能力的同時，減少了參數量與每步的狀態傳遞開銷。Cho et al.指出，GRU 的每個隱藏單元具備獨立門控，可自適應地捕捉不同時間尺度的依賴關係，這一特性對於本研究中 SOC 累積效應與開關投切歷史並存的多尺度時序依賴情境尤為契合。

綜合上述考量，本研究以 GRU 作為預設時序記憶模組。此選型的具體性能驗證，包含 LSTM 與 GRU 在固定初始 SOC 及隨機初始 SOC 條件下的收斂表現比較，將於第五章比較分析中進行量化分析。

3.5 圖神經網路 (Graph Neural Network, GNN)

電力系統的物理結構天然形成一個圖 (Graph)：各匯流排是圖的節點，各支線與 Tie-line 是圖的邊，此圖結構蘊含了豐富的電氣拓撲資訊，包含連通性、孤島結構與潮流路徑等。傳統的全連接神經網路對輸入特徵進行逐元素的線性變換，將所有節點特徵拼接為平鋪向量處理，完全忽略了節點之間的空間鄰接關係，無法讓模型感知「哪些節點相鄰」以及「相鄰節點的狀態如何影響自身」等拓撲資訊。圖神經網路 (Graph Neural Network, GNN) 是一類專門為處理圖結構資料設計的深度學習框架，其核心操作為逐層傳播規則：每層將節點特徵與鄰接結構結合，透過加權聚合與非線性變換更新節點表示，使每個節點的特徵向量能夠捕捉其局部拓撲環境的資訊。其中圖卷積網路 (Graph Convolutional Network, GCN) 是應用最廣泛的變體之一，其數學形式與設計原理詳見 3.5.1 節。

值得注意的是，Fan et al.在單代理人復電框架中採用了 bus 層級的 GCN，以動態鄰接矩陣捕捉電網內部的細粒度拓撲關係，並將提取的潛在圖特徵接入 LSTM 時序記憶模組[6]。然而在多代理人情境下，各 MG 的 bus 電氣特徵是全域潮流計算的結果，同時受到所有代理人動作的影響，使得本地鄰接矩陣無法完整解釋 bus 特徵的變化來源，bus 層級 GCN 的學習假設在此情境下難以成立。此外，DTDE 架構下各代理人僅

能透過跨 MG 線路取得鄰居的有限狀態資訊，跨 MG 的 bus 層級特徵不可得，進一步排除了跨代理人細粒度圖聚合的可行性。因此本研究選擇在代理人層級執行圖聚合，以鄰居代理人的完整觀測向量作為聚合輸入，並依賴 GRU 時序記憶隱式補償外部代理人動作對本地特徵的影響，具體設計詳見 3.5.3 節。

3.5.1 圖卷積網路

Kipf 與 Welling 於 2017 年提出圖卷積網路 (Graph Convolutional Network, GCN)，是 GNN 中最廣泛應用的變體之一[19]。GCN 將譜域圖卷積近似為簡潔的節點局部鄰域聚合操作，給定圖 $G=(N,E)$ 的鄰接矩陣 $A \in \{0,1\}^{n \times n}$ 與節點特徵矩陣 $X \in \mathbb{R}^{n \times d}$ ，第 l 層的節點特徵更新公式為：

$$H^{(l+1)} = \sigma(\tilde{D}^{-1/2} \tilde{A} \tilde{D}^{-1/2} H^{(l)} W^{(l)}) \quad (3.24)$$

其中 $\tilde{A} = A + I_n$ 為加入自環後的鄰接矩陣，確保節點在聚合時也考慮自身特徵； $\tilde{D}$ 為 $\tilde{A}$ 的對角度數矩陣； $H^{(l)}$ 為第 l 層的節點特徵矩陣， $H^{(0)} = X$ ； $W^{(l)}$ 為可學習投影矩陣； $\sigma(\cdot)$ 為非線性激活函數。對稱正規化因子 $\tilde{D}^{-1/2} \tilde{A} \tilde{D}^{-1/2}$ 同時考慮傳送端與接收端的節點度數，避免高連接度節點對鄰居產生過度主導的影響，此特性對連接度差異顯著的電網拓撲尤為重要。

3.5.2 圖聚合設計

Hu et al. 在 D3-AC 演算法中，針對同質多代理人問題將 GCN 引入 Critic 網路的設計，其主要動機在於：當代理人數量增加時，以 MLP 直接拼接聯合觀測的輸入維度線性增長，導致可擴展性問題；而 GCN 的參數規模與代理人數量無關，天然具備可擴展性[9]。其圖卷積層公式為：

$$h^k = \sigma\left(h^{k-1} W_l^s + \frac{1}{N} S h^{k-1} W_l^o\right) \quad (3.25)$$

其中 $h^k \in \mathbb{R}^{N \times Z_k}$ 為第 k 層的輸出； S 為對角線為零的全一矩陣，用於提取代理人間

的交互資訊； W_l^s 與 W_l^o 分別為自身與他人的獨立可學習權重矩陣； $\frac{1}{N}$ 為全體代理人的均值歸一化因子。

此設計建立在兩個前提之上。其一，D3-AC 的 Critic 以聯合觀測 $o_t = (o_t^1, \dots, o_t^N)$ 為輸入，各代理人可依據同質性條件從自身觀測在本地推算其他代理人的觀測，因此 Critic 在本地即可持有完整的 $h^{k-1} \in \mathbb{R}^{N \times Z_{k-1}}$ ，並對全體 N 個代理人執行均值聚合。其二，自身資訊與鄰居資訊以獨立權重矩陣 W^s 、 W^o 分開處理，允許模型對兩類資訊學習不同的特徵投影，但自身與鄰居的混合比例由網路隱式決定。

Hu et al. 的 Theorem 1 進一步指出，在同質代理人（homogeneous agents）的條件下，最優解可限制在所有代理人共享相同策略的空間內求得，這為後續的策略共識機制提供了理論依據，並在本研究的 GNN 設計中體現為共享權重的歸納偏置。

3.5.3 本研究之加權局部聚合設計

本研究的多代理人情境與 D3-AC 存在四個根本性的前提差異，促使 GNN 聚合設計需要相應調整。

差異一：Critic 聯合觀測 → 本地隱狀態

D3-AC 的 GCN 位於 Critic 網路內部，Critic 以聯合觀測 o_t 為輸入，依賴同質性條件在本地推算全體代理人的觀測，從而執行圖聚合。本研究採用 DTDE 架構，Critic 僅以本地隱狀態 (h_t, a_t) 為輸入，無法在 Critic 內部取得其他代理人的觀測以執行圖聚合。因此，圖聚合必須前移至觀測端，在觀測進入時序記憶模組前，先完成空間特徵融合。

差異二：全體代理人聚合 → 1-hop 鄰居聚合

D3-AC 的 Critic 在本地持有全體 N 個代理人的特徵， $\frac{1}{N} Sh^{k-1}$ 對所有代理人的特徵執行均值聚合。本研究中圖聚合位於觀測端，各代理人的可聚合資訊受限於物理跨 MG 線路的連接拓撲，僅能取得直接相鄰 1-hop 鄰居的觀測，因此歸一化改採度正規

化：

$$w_{ij} = \frac{1}{|\mathcal{N}_i|}, \quad j \in \mathcal{N}_i \quad (3.26)$$

其中 $\mathcal{N}_i$ 表示代理人 i 的 1-hop 鄰居集合， $|\mathcal{N}_i|$ 為鄰居數量。

差異三：功能性雙權重 $\rightarrow$ 完全共享權重

D3-AC 在同質代理人框架下，仍為自身資訊與鄰居資訊設置獨立的投影權重 W^s （自身）與 W^o （他人）。以允許模型對兩種角色學習不同的特徵投影。本研究依據 Hu et al. 的 Theorem 1 所揭示的同質代理人可共享策略的結論，以及五個微電網面對相似控制任務、動作空間語義一致的設計前提，將共享原則延伸至 GNN 的特徵投影設計，令自身與鄰居共用同一組 W_{graph} 。

此設計的核心考量在於：五個 MG 面對相同性質的控制挑戰，有用的特徵模式在代理人間具有相似性，共享投影層可學習一種適用於所有代理人的通用特徵提取能力，同時將參數量減少為雙權重設計的一半。

W_{graph} 亦將自身與鄰居投影至同一特徵空間，使後續加權混合在語義一致的空間內操作。自身與鄰居的混合比例則由顯式純量 α_{self} 直接控制詳見差異四，其部分補償了放棄雙權重後對兩者角色差異的顯式建模能力。

差異四：隱式學習自身比例 $\rightarrow$ 顯式純量控制

標準 GCN 透過自環 $\tilde{A} = A + I_n$ 隱式納入自身特徵，自身與鄰居共用同一組投影權重，自身保留的比例由正規化因子隱式決定。D3-AC 雖以獨立權重矩陣 W^s 將自身資訊與鄰居資訊顯式分離，但兩者的混合比例仍由網路在訓練中隱式學習，無法直接設定。在 DTDE 情境下，代理人無法觀測鄰居在前一時步的動作輸出，時步 t 的鄰居觀測向量是鄰居在時步 $t-1$ 的動作結果，但動作本身不可得，導致鄰居觀測的因果資訊不完整；在此資訊不確定性下，以可學習注意力機制動態調整鄰居聚合權重的邊際效益有限，同時在固定通訊拓撲下度數歸一化的統計優勢不顯著。因此以顯式純量

$a_{self} \in [0,1]$ 取代隱式學習機制，使自身特徵與鄰居特徵的混合比例可直接設定與調整：

$$\xi_i = \text{ReLU} \left(\text{LN} \left(\alpha_{self} \cdot W_{graph} \cdot o_i + (1 - \alpha_{self}) \cdot \sum_{j \in \mathcal{N}_i} w_{ij} \cdot W_{graph} \cdot o_j \right) \right) \quad (3.27)$$

其中 $W_{graph} \in \mathbb{R}^{128 \times d_{obs}}$ 為 GNN 的線性投影層，self 與鄰居共用同一組權重以確保特徵空間統一； $w_{ij} = \frac{1}{|\mathcal{N}_i|}$ 為度正規化鄰居權重；激活函數採用 Pre-norm 風格 $\text{ReLU}(\text{LN}(\cdot))$ ，

先對混合特徵執行 LayerNorm，再施加 ReLU 非線性，確保 ξ_i 進入 GRU 前的數值尺度穩定，有利於循環網路的訓練收斂。當代理人 i 無直接鄰居時，公式退化為純自身特徵投影： $\xi_i = \text{ReLU}(\text{LN}(W_{graph} \cdot o_i))$ 。 a_{self} 的最終取值由比較分析實驗確定，具體評估結果詳見第五章。

整體而言，本研究的 GNN 聚合設計在精神上接近 GraphSAGE[20] 的 mean aggregator，其以共享可學習線性層對自身與鄰居特徵各自投影後加權合併，並以顯式係數 a_{self} 分離自身與鄰居的貢獻，而非採用 GCN 的頻譜歸一化方式。

聚合後的空間特徵 ξ_i 接續輸入 GRU 時序記憶模組，形成兼顧空間拓撲資訊與時序依賴的複合隱狀態 $h_t = \text{GRUCell}(\xi_t, h_{t-1})$ 如圖 3.5，為 Actor 與 Critic 的決策提供依據。




圖 3.5 GNN+GRU 架構

3.6 多代理人策略協調機制

本節介紹本研究在 DTDE 架構下處理多代理人協調問題的兩項機制：策略共識 (Policy Consensus, PC) 與連勝鎖 (Streak Lock)。前者透過週期性參數共識使各代理

人策略趨向一致如圖 3.6，後者在共識操作中保護已收斂的優質策略不被稀釋。

3.6.1 策略共識機制 (Policy Consensus, PC)

策略共識 (Policy Consensus, PC) 機制的數學基礎源於多代理人系統的參數共識理論：各代理人的網路參數透過鄰域加權平均操作，在參數空間中逐漸趨向一致，從而在不依賴集中式調度器的前提下實現「軟性」的策略協調。Hu et al.在 D3-AC 中將此機制引入分散式多代理人強化學習，分別對 Actor 與 Critic 參數執行共識更新。本研究沿用此設計，對 Actor、Critic1 與 Critic2 的完整網路參數執行共識更新，以固定週期執行一次。

各代理人 i 的 Actor 參數 θ_i 與兩個 Critic 參數 $\omega_{i,1}$ 、 $\omega_{i,2}$ 按照列隨機矩陣 W_{actor} 、 W_{critic} 進行加權平均更新：

$$\theta_i^{new} = \sum_j W_{actor}[i, j] \cdot \theta_j \quad (3.28)$$

$$\omega_{i,k}^{new} = \sum_j W_{critic}[i, j] \cdot \omega_{j,k}, \quad k \in \{1, 2\} \quad (3.29)$$

列隨機 W 矩陣的結構設計如下：對角元素為自身保留係數 w_{self} ；非對角的鄰居元素為剩餘權重均分於所有直接鄰居：

$$w_{ii} = w_{self} \quad (3.30)$$

$$w_{ij} = \frac{1 - w_{self}}{|N_i|}, \quad j \in N_i \quad (3.31)$$

$$\sum_j w_{ij} = 1 \quad (3.32)$$

本研究採用非對稱設計： $w_{self}^{Actor} = 0.8$ ， $w_{self}^{Critic} = 0.85$ 。Actor 保留係數設為較低的 0.8，基

於以下考量：各代理人的 Actor 輸出同一動作語義空間 $[-1, +1]^{d_i}$ 中的連續向量，在控制目標相似的微電網之間，鄰居的 Actor 參數在語義上具有可平均性，較積極的共識更新有助於加速策略同步，尤其在訓練初期不同代理人收斂速度不一致時。Critic 保留係數

設為較高的 0.85，基於以下考量：各代理人的 Critic 評估其局部觀測環境下的動作價值，不同微電網的局部狀態分佈差異顯著，過度強制統一可能破壞各代理人 Critic 對自身局部環境的適配性，引入估計偏差。非對稱設計的有效性由比較分析實驗驗證，具體結果詳見第五章。

PC 共識完成後，系統立即以快速軟更新速率 $\tau_{fast} = 4\tau$ 同步所有代理人的目標網路 $\bar{\phi} \leftarrow \tau_{fast}\phi + (1-\tau_{fast})\bar{\phi}$ ，防止策略參數共識後 Bellman 訓練目標暫時失準，維持訓練的連續性。




圖 3.6 Agents 資訊流動

3.6.2 連勝鎖（Streak Lock）機制

連勝鎖以每個代理人的連續成功計數器追蹤其近期表現。計數規則為：達到回合中 24 步均復電成功時成功計數器累加；部分達標 $22 \leq \text{Good} < 24$ 時成功計數器歸零；連續差成績 $\text{Good} < 22$ 時 poor 計數器累加。當成功計數器達到門檻值且同時滿足 ESS SOC 標準差低於上限，其為防止「以 SOC 不均衡為代價的高成功率」策略被誤鎖定，代理人進入鎖定狀態，在後續 PC 週期中暫停 Actor 與 Critic 的共識更新及目標網路加速同步；各代理人的本地梯度訓練不受影響，仍持續以自身經驗進行策略微調。

解鎖觸發條件有二：若 poor 計數器達到門檻，即為策略出現退化跡象，強制解鎖

讓代理人重新從鄰居學習；若鎖定持續超過最大鎖定回合數上限，無條件強制解鎖，防止代理人因過長鎖定而與整體訓練脫節。

3.7 雙池經驗回放記憶架構

強化學習的樣本效率問題在電網潮流模擬場景中尤為突出：每個時間步的環境交互需要呼叫 PandaPower 進行完整的潮流計算，計算代價遠高於 Atari 或 MuJoCo 等標準基準環境，使得提升樣本利用效率成為設計回放記憶機制的核心挑戰。

標準的均勻經驗回放（Uniform Experience Replay）[14]對記憶區中所有樣本等機率取樣，在訓練初期稀少的高品質樣本被大量失敗樣本淹沒，代理人難以快速從成功軌跡中學習有效策略。優先經驗回放（Prioritized Experience Replay, PER）[21]透過 TD 誤差加權取樣提升重要樣本的取樣頻率，但 TD 誤差高的樣本未必對應高策略學習價值：TD 誤差反映的是模型對轉移的預測驚訝程度，而非任務層面的策略示範品質。在稀疏成功獎勵的復電場景中，TD 誤差難以區分「值得高頻學習的成功軌跡」與「因模型尚未適應而誤差偏高的失敗樣本」，可能導致代理人過度學習對復電目標貢獻有限的轉移。

本研究提出雙池經驗回放記憶架構，以任務層面的多維成功標準作為樣本優先化依據，而非單一的 TD 誤差指標，構建高品質樣本的獨立儲存與高頻取樣通道。

3.7.1 雙池架構設計

雙池經驗回放記憶架構由兩個以回合為單位的經驗回放區組成。各代理人共用同一份取樣索引序列，確保 GNN 聚合在訓練時能正確重現執行序列（rollout）時的鄰居觀測，維持跨代理人樣本的時序對應關係。此協調機制僅作用於取樣索引的同步，各代理人仍從各自的本地緩衝區取出對應的觀測、動作與獎勵序列進行獨立更新，不涉及環境資訊或策略資訊的跨代理人共享，與 DTDE 架構的分散式本質不衝突。

- 普通池（Normal Pool）容量為 2,000 個完整回合，採用先進先出（First In First

Out, FIFO) 策略，儲存所有回合的轉移序列，保障策略探索的多樣性基礎，確保代理人不因過度依賴精英樣本而喪失對新情境的泛化能力。

- 精英池 (Elite Pool) 容量為 500 個完整回合，僅儲存滿足嚴格品質篩選條件的成功回合軌跡，為代理人提供高品質的策略示範，加速策略收斂。

訓練時採固定比例的混合取樣：精英池貢獻 25%、普通池貢獻 75% 的批次樣本，在學習效率與探索多樣性之間取得平衡。

3.7.2 四項精英篩選條件

一個回合軌跡納入精英池需同時滿足以下四項條件：

條件一、完美任務完成：全時段復電持續時間達 24 步，即本回合全部 24 個時間步均維持三個關鍵負載供電，達到零中斷的完美復電效果。

條件二、SOC 均衡上限：回合內任意時步各 ESS SOC 標準差低於 25%，確保儲能資源在各代理人之間均衡分佈，避免部分 ESS 過度放電而其他 ESS 閒置的不均衡現象。

條件三、SOC 均衡下限：回合結束時各 ESS SOC 標準差不低於 8%。此下限條件防止各 ESS SOC 過度趨同的回合被納入精英池，無論是各 ESS 均等放電至相近低水準，或均等保留至相近高水準，此類策略犧牲了儲能差異帶來的調度靈活性，不應作為高品質示範。下限 8% 的設定依據在於：在隨機初始 SOC 條件下，5 個 MG 各自獨立取樣的初始 SOC std 理論最大值恰為 8%，若末步 SOC std 低於此值，代表策略的末步能量分布比純隨機起點更為均一，即策略以同步放電模式應對任務而非執行差異化的跨 MG 協調。

條件四、獎勵品質：回合累積獎勵超過動態獎勵門檻，門檻定義為近 200 個回合獎勵的第 75 百分位數，確保精英池中的樣本在累積獎勵層面達到相對高水準，過濾偶發性達標但整體控制品質欠佳的回合。

四項 AND 篩選條件的設計哲學在於：從任務完成、儲能均衡範圍與整體效益四個互補的約束維度共同定義「高品質策略軌跡」的標準，確保精英池中的樣本所展示的

是真正意義上的多目標最優策略行為，而非在某一維度上表現突出但在其他維度存在缺陷的次優策略。只要任一條件不滿足，該回合軌跡即被排除在精英池之外，僅存入普通池。

第四章 模擬環境建立與實作方法

本研究所建立的訓練環境 IEEE123_DTDE_Env 是連接理論演算法與電網物理現實的橋樑，其設計品質直接決定代理人所學習策略的實用性與可靠性。一個優秀的強化學習環境需要在以下幾個維度取得平衡：物理真實性（潮流計算結果準確反映電氣現象）、計算效率（能夠支撐數千回合的訓練迭代）、多樣性（覆蓋足夠豐富的故障與初始條件場景以促進泛化）以及訓練信號的清晰性（獎勵函數設計能夠有效引導策略向多目標最優方向收斂）。

本章依序介紹環境的各核心組件。第 4.1 節說明電力系統圖論表示、孤島偵測與代理人通訊拓樸；第 4.2 節說明 PandaPower 工具的選用依據與 DER 不確定性模型；第 4.3 節描述 IEEE 123-bus 系統的五微電網分區與 DER 配置；第 4.4 節逐一介紹 IEEE123_DTDE_Env 環境模組的各功能組件，包括 Gym 介面、觀測結構、環境初始化、Virtual Slack 機制、動作執行流程與 15 項獎勵函數；第 4.5 節說明完整的訓練排程設計，包括探索噪聲策略、Anti-stagnation 機制、崩潰恢復邏輯與完美收斂判定準則，並以演算法偽程式碼統整整體訓練流程。

4.1 電力系統圖論基礎

電力網路的物理結構本質上是由匯流排節點與線路、開關、Tie-line 邊構成的離散連接關係，這種結構與圖論所研究的數學物件高度吻合，因此圖論（Graph Theory）為電力系統的拓樸分析提供了嚴謹的數學語言。以圖的方式表示電力網路，不僅能夠系統化描述各匯流排、支線、Tie-line 的連接關係，也是孤島偵測演算法、代理人通訊拓樸設計以及圖神經網路特徵聚合的共同數學基礎。這三個子問題雖然應用目的不同，分別對應主網斷線後的孤島範圍判定、代理人之間通訊邊的建立、以及鄰居節點特徵的聚合方式，但若各自採用不同的網路表示方式，將需要額外的資料結構轉換，也可能因定義不一致而產生落差。因此，本研究採用統一的圖結構表示作為三者共同的數學基礎，確保孤島偵測、通訊拓樸與 GNN 聚合三者拓樸定義上具有內在一致性。

4.1.1 電網圖模型

本研究將 IEEE 123-bus 配電網路以無向加權圖 $G=(N,E)$ 表示，節點集合 N 對應系統的 130 個匯流排，邊集合 E 對應系統的支線與 Tie-line 連接。

每個節點 $n_i \in N$ 在時間步 t 的特徵向量包含多維物理屬性：節點類型標記 `is_load`、`is_pv`、`is_ess`、`is_statcom`、`is_critical` 均為布林量，電壓幅值 $V_{i,t}$ p.u.，正常範圍 0.95-1.05，有功與無功負載需求 $P_{load,i}$ 、 $Q_{load,i}$ ，並以系統 S_{base} 正規化，PV 預測出力 $P_{pv,i}^{exp}$ ，以及 ESS 電量狀態 $SOC_{i,t}$ 。所有節點特徵向量按行堆疊，形成節點特徵矩陣 $X_t \in \mathbb{R}^{130 \times d}$ 。

邊 $e_{ij} \in E$ 附帶電氣參數：電阻 $r_{i,j}$ p.u.、電抗 $x_{i,j}$ p.u.、額定視在功率容量 S_{ij}^{max} MVA，以及動態更新的開關狀態 $u_{ij,t} \in \{0,1\}$ ，其 1 表示連通，0 表示斷開。圖的鄰接矩陣 $A_t \in \{0,1\}^{130 \times 130}$ 隨代理人的 Tie-line 投切操作動態更新，此動態鄰接矩陣 A_t 在本研究中承擔兩項功能：其一，作為第 4.1.2 節孤島偵測演算法的輸入，透過連通分量分析確定當前時間步各匯流排的電氣孤島歸屬；其二，透過每個時間步的潮流計算間接影響節點特徵矩陣 X_t 的內容如電壓幅值與供電狀態等，使觀測特徵隨 Tie-line 投切動態更新。

4.1.2 連通分量孤島偵測

在電網圖模型建立後，孤島偵測基於圖的連通分量（Connected Components）分析來識別每個孤立供電區域。當電網因支線斷路或 Tie-line 斷開而出現不連通結構時，不同連通分量內的節點之間無法進行電力交換，各自形成獨立的供電孤島，每個孤島的功率平衡需在其內部的發電資源（ESS、PV）與負載之間獨立達成。值得注意的是，每個孤島需要指定一個參考節點（Virtual Slack）以使潮流計算收斂，孤島偵測因此也

是 Virtual Slack 競選機制的前置步驟，詳見第 4.4 節。

本研究採用 PandaPower 的內建圖論工具實現孤島偵測：調用 `pandapower.topology.create_nxgraph` 函數，依據電網的當前開關狀態建立對應的 NetworkX 無向圖 G_l ；接著調用 `pandapower.topology.connected_components`，在 $O(|N|+|E|)$ 的時間複雜度內遍歷全部節點，輸出所有連通分量的集合 $\{C_1, C_2, \dots, C_k\}$ ，每個連通分量 C_m 即對應一個孤島區域中的匯流排集合。

孤島偵測結果在環境的多個功能模組中被使用：在 Virtual Slack 指派時確定每個孤島內的候選 ESS 節點集合；在潮流計算前判斷關鍵負載所在孤島是否包含可用發電資源，若關鍵負載所在孤島無任何 ESS 或 PV，則無論代理人採取何種動作，該步無法恢復供電，直接記錄為復電失敗；在獎勵計算中確定各孤島的停電比例，未供電匯流排在本 MG 管轄匯流排中的佔比。

4.1.3 代理人通訊圖與共識矩陣

代理人間的策略共識操作依賴一個獨立的代理人級通訊圖 $G_{comm} = (N_{agent}, E_{comm})$ ，其中 $N_{agent} = \{MG0, MG1, MG2, MG3, MG4\}$ 為 5 個代理人節點， E_{comm} 的判定原則延續 3.5 節所建立的物理結構優先原則：凡兩端 bus 分屬不同 MG 者，即視為一條通訊邊，此判定不依賴元件的 type 標記或當前開關狀態，而僅依據 bus 的物理 MG 歸屬，確保通訊拓撲作為 GNN 聚合輸入的結構穩定性，若鄰居關係隨開關狀態動態變化，將代理人在不同時間步所聚合的空間資訊來源不一致，GRU 時序記憶模組將接收到語義不穩定的輸入序列，使其難以學習一致的時序依賴模式。

本研究系統的跨 MG 連接，除 5 條新增的跨 MG Tie-line 外，原始網路中有兩條既存線路亦分別連接 $MG0 \leftrightarrow MG2$ 與 $MG1 \leftrightarrow MG4$ ，因其物理上同樣構成 MG 之間的資訊交換路徑，依前述物理結構優先原則納入通訊拓撲。完整的跨 MG 連接如表 4.1 所示：

表 4.1 跨 MG 通訊拓樸

Tie-line/開關	匯流排端點	連接代理人	元件類型
線路 1	bus 149 ↔ bus 250	MG0 ↔ MG1	新增 Tie-line
線路 2	bus 35 ↔ bus 54	MG1 ↔ MG2	新增 Tie-line
線路 3	bus 57 ↔ bus 81	MG2 ↔ MG3	新增 Tie-line
線路 4	bus 64 ↔ bus 67	MG2 ↔ MG4	新增 Tie-line
線路 5	bus 95 ↔ bus 114	MG3 ↔ MG4	新增 Tie-line
線路 6	Bus 151 ↔ bus 300	MG1 ↔ MG4	原始 Tie-line
線路 7	bus13↔bus152	MG0↔MG2	原始開關

本研究的通訊拓樸由 7 條跨 MG 連接構成，MG2 位於拓樸中心，同時與 MG0、MG1、MG3、MG4 相連。各代理人的鄰居數為：MG0 有 2 個（MG1、MG2），MG1 有 3 個（MG0、MG2、MG4），MG2 有 4 個（MG0、MG1、MG3、MG4），MG3 有 2 個（MG2、MG4），MG4 有 3 個（MG1、MG2、MG3）。此鄰居結構同時作為 3.5 節

GNN 度正規化權重 $w_{ij} = \frac{1}{|N_i|}$ 與 3.6 節策略共識矩陣的鄰接基礎，具體的共識權重矩陣

構造與非對稱設計理由詳見 3.6 節。

代理人通訊圖 G_{comm} 為 MG 層級的 5 個節點稀疏圖，與 130 個節點電網物理圖 G 在層次上不同：前者作為 GNN 空間聚合的通訊邊，定義代理人之間可交換觀測資訊的範圍；後者作為潮流計算的物理基礎，描述電氣設備間的連接關係。兩者共同支撐本研究多代理人決策架構的空間資訊感知與物理模擬能力。

4.2 PandaPower 潮流分析工具

電力系統潮流計算（Power Flow Analysis）是確定穩態運行條件下系統各節點電壓、各支線功率分佈的核心計算工具，在本研究的環境模擬中扮演「物理現實驗證器」的角色，代理人的每一個控制動作在執行後，必須通過潮流計算確認其是否導致

電壓越限、線路過載或供需失衡等違規現象，潮流計算的結果直接決定獎勵信號的各項懲罰分量。

4.2.1 電力系統模擬工具比較與選用

強化學習研究中常用於配電系統模擬的工具涵蓋開源與商業軟體，各工具在建模精度、元件支援、Python 整合性與孤島處理能力上存在顯著差異。本節比較四種在相關文獻中常見的工具如表 4.2，並說明本研究選 PandaPower 的主要考量。

表 4.2 電力系統模擬工具功能比較

比較維度	PandaPower	PyPower / MATPOWER	OpenDSS	GridLAB-D
開發背景	德國卡塞爾大學， 2018 年[22]	PSERC，1997/2011 年 [23]	EPRI，2000 年代[24]	美國能源部， 2008 年[25]
資料模型	物件導 DataFrame (pandas)	MATLAB 矩陣格式 (numpy array)	腳本式元件描述 (DSS 語法)	物件導向 (GLD 物件)
電網元件 支援	ESS、STATCOM、 PV 完整支援	基本元件，需手動擴展	DER、儲能完整支援	分散式能源、智 慧電錶
圖論整合	內建 NetworkX 接 口	無，需另行建立	無原生圖論接口	無原生圖論接口
孤島自動 處理	自動偵測並分離孤 島，各孤島獨立求 解	不支援，需手動指定 Slack	支援，需額外配置	有限支援
三相不平 衡	支援	不支援（單相等效）	完整支援三相不平衡	完整支援三相不 平衡
Python 整 合性	原生 Python / pandas，API 完整	MATLAB 移植，部分 功能受限	透過 COM/DLL 呼 叫，整合較複雜	透過 Python 介 面

- PandaPower [22]：最大優勢在於其對孤島配電網的原生支援：呼叫

pandapower.runpp 時，若電網存在多個孤立子圖，工具自動識別各孤島並分別指定

合適的 Slack 進行獨立的潮流計算，無需外部程式手動介入，大幅簡化了孤島復電情境的模擬邏輯。此外，PandaPower 與 NetworkX 的深度整合使得孤島偵測與潮流計算共享同一套圖結構表示，減少資料轉換的開銷。

- OpenDSS [24]：在三相不平衡配電網的模擬精度上具有優勢，亦支援 DER 元件，Fan et al. 的 RGSAC 研究即採用 OpenDSS 作為模擬環境。然而，OpenDSS 透過 COM/DLL 介面呼叫，在 Python 整合的便利性與 NetworkX 圖論工具的接入上不如 PandaPower 直接，且其腳本式的元件描述語法在動態修改電網拓樸的情境下程式碼複雜度較高。
- PyPower / MATPOWER [23]：輸電網研究的經典工具，其矩陣格式的資料模型對大規模輸電網優化問題高效，但對孤島配電網的支援不足，且缺乏 ESS、STATCOM 等元件的原生建模能力。
- GridLAB-D [25]：專注於配電系統的動態模擬，其應用場景以電力市場、需求響應與智慧電錶模擬為主，與本研究孤島復電情境的核心需求如動態拓樸切換、即時潮流驗證契合度較低。

基於上述比較，本研究選用 PandaPower 作為潮流計算工具，以確保計畫性孤島復電情境的模擬完整性與 Python 訓練框架的無縫整合。

4.2.2 潮流計算

PandaPower 基於 Newton-Raphson 迭代法求解潮流方程，對配電網路的非線性功率平衡方程組進行迭代求解，包含有功功率 P 與無功功率 Q 。對系統中任意節點 i ，有功與無功功率注入方程為：

$$P_i = \sum_j |V_i| |V_j| |Y_{ij}| \cos(\theta_{ij} - \delta_i + \delta_j) \quad (4.1)$$

$$Q_i = \sum_j |V_i| |V_j| |Y_{ij}| \sin(\theta_{ij} - \delta_i + \delta_j) \quad (4.2)$$

其中 $|V_i|$ 、 δ_i 分別為節點 i 的電壓幅值與相角， $|Y_{ij}|$ 、 θ_{ij} 為節點導納矩陣第 (i, j) 元素的

幅值與相角。Newton-Raphson 法每次迭代通過求解線性修正方程更新電壓向量

$$\begin{bmatrix} \Delta P \\ \Delta Q \end{bmatrix} = J(\delta, |V|) \cdot \begin{bmatrix} \Delta \delta \\ \Delta |V|/|V| \end{bmatrix} \quad (4.3)$$

其中 J 為雅可比矩陣，包含 $\partial P/\partial \delta$ 、 $\partial P/\partial |V|$ 、 $\partial Q/\partial \delta$ 、 $\partial Q/\partial |V|$ 四個子矩陣， ΔP 、 ΔQ 為節點有功與無功的功率不平衡量。每次迭代更新 $[\delta, V]$ 並重新計算 ΔP 、 ΔQ ，直至最大不平衡量低於收斂閾值。潮流計算成功收斂後，系統獲得所有匯流排的電壓幅值 $|V_i|$ 與相角 δ_i ，以及所有支線的有功功率流 P_{ij} 、無功功率流 Q_{ij} 和視在功率流 S_{ij} ，這些結果是驗證電壓合規性與支線容量合規性的依據。

相較於線性化潮流（LinDistFlow）[26]等近似方法，本研究採用完整潮流計算有以下考量：LinDistFlow 在推導時假設支線上的功率損耗相對於功率流量可忽略，此簡化在低負載率下誤差較小，但本研究的電網包含孤島運行、大量 DER 出力波動與無功補償，支線負載率與損耗占比在某些時間步可能顯著，忽略損耗項將降低電壓越限判定的精度。本研究的電網包含孤島運行、大量 DER 出力波動與無功補償，電壓與有功/無功的非線性耦合效應較為顯著，完整潮流確保了電壓越限懲罰信號的計算精度。值得對照的是，Wang et al. 的 H2MAPPO 研究採用線性化 AC-OPF（LinDistFlow）由集中式控制器（MGCC）收集全體代理人動作後統一求解，其 Critic 訓練機制亦倚賴此集中聚合的資訊，這在計算效率上具有優勢；本研究的 DTDE 架構下各代理人無法依賴集中式求解器，因此在環境層面嵌入完整物理潮流驗證是確保訓練信號品質的必要設計。

4.2.3 DER 出力不確定性模型

分散式能源的出力因天候變化而存在隨機不確定性，這是本研究將復電問題建模為 POMDP 框架的重要物理依據之一，即代理人在每個時間步所能觀測的是 PV 的基礎預測值，而非受天候擾動後的實際出力，決策必須在不完全資訊下進行。Fan et al. 的 RGSAC 研究亦基於相同的物理動機，將 DER 出力不確定性納入 POMDP 建模框架，

並指出此類不確定性是配電網復電策略學習的核心挑戰。

本研究採用如下每步同步擾動機制：在每個時間步，PV 出力與負載需求以相同的均勻分佈隨機係數同步擾動：

$$P_{pv,t}^{actual} = P_{pv,t}^{base} \times \varepsilon_t, \quad P_{load,t}^{actual} = P_{load,t}^{base} \times \varepsilon_t, \quad \varepsilon_t \sim U(0.95, 1.05) \quad (4.4)$$

代理人在決策時能觀測的是基礎預測值 P_{pv}^{exp} ，由當前時段 PV 出力乘以 PV 裝置容量與系統總負載的比值動態計算，確保模型在不同容量配置的電網上正確運行，而非採用固定倍數的靜態設定。此設計使代理人的決策始終帶有觀測不確定性，強制代理人學習具備一定容錯能力的保守策略。

Fan et al. 的 RGSAC 研究採用 7 天預測資料集並以多模態特徵觀測空間 (multimodal feature-based observation space) 應對 DER 不確定性，同時以 LSTM 的記憶資訊補償不可觀測的發電容量。本研究採用逐步均勻擾動的設計較為簡潔，在不引入額外預測模型的前提下產生訓練場景的隨機多樣性，並以 GRU 記憶模組承擔跨時步資訊補償的功能詳見第 3.4 節，兩種設計在處理 POMDP 不確定性的技術路線上有所不同，但核心動機一致。

4.3 IEEE 123-bus 系統設定

主網斷線後，原本由變電站端提供的電力參考消失，但孤島內的 Newton-Raphson 潮流計算仍需要一個 Slack 節點提供參考值才能收斂求解，因此每個孤島內需指定一個 Virtual Slack 角色承接這個功能。由於 Virtual Slack 需吸收孤島內瞬時的功率供需缺口，其角色對 ESS 的能量餘裕要求較高，因此本研究讓各孤島內電量狀態最高的 ESS 動態擔任此角色，而非預先指定固定的某一台 ESS，這樣可確保承擔 Slack 功能的單元始終具備相對充裕的能量餘裕，降低因 SOC 耗盡而無法維持電壓參考的風險。STATCOM 則補償孤島內的無功需求，以維持電能品質與潮流計算的收斂性。此類微電網孤島復電情境普遍見於電力系統韌性文獻[27]。

4.3.1 IEEE 123-bus 測試系統

本研究選用 IEEE 123-bus 測試饋線的原因在於，後續章節需要將系統劃分為 5 個微電網並驗證跨 MG 協調機制，這要求測試系統具備足夠的節點數與分支複雜度以支撐有意義的分區規模；節點數較少的標準測試饋線如 13-bus、34-bus 難以劃分出兼具規模與複雜度的多個微電網區域。IEEE 123-bus 配電測試饋線由 IEEE 配電系統分析小組委員會設計，是配電系統分析與控制研究中廣泛採用的標準測試平台。

原始 IEEE 123-bus 系統為三相不平衡配電系統，若直接採用三相建模，每個節點的狀態與動作維度將隨之增加三倍，對多代理人強化學習的觀測空間與訓練計算負擔造成顯著影響。因此，本研究的電網資料採用單相等效模型，在統一電壓等級 4.16 kV 下運行，系統總有功負載為 1,163 kW，共 130 個匯流排。

Fan et al. 的 RGSAC 研究與本研究均採用 IEEE 123-bus 系統作為測試平台，但兩者在系統規模與建模方式上有所差異：RGSAC 將系統簡化為 15 個節點單元以提升演算法效率，本研究保留完整的 130 個匯流排以確保物理模擬的精度。原始 IEEE 123-bus 系統為三相不平衡配電系統，總負載約 3,385 kW[28]；本研究採用單相等效模型，系統負載縮減至原始值的約三分之一，與單相等效的物理意義一致。

4.3.2 微電網分區與關鍵負載設計

本研究依照地理分區與電氣連接特性，將 IEEE 123-bus 系統劃分為 5 個微電網區域 MG0-MG4。配電網路劃分為多個微電網的問題，在電力系統韌性文獻中已發展出多種方法，涵蓋圖論、啟發式規則、分群演算法與混合整數規劃等[29]，其核心設計目標普遍聚焦於最大化各微電網的自給自足能力（self-adequacy）：併網運行時最小化微電網間的功率交換，孤島運行時確保各微電網內部的發電與負載達到平衡。本研究採用啟發式的地理與電氣拓撲分區方式，而非透過正式最佳化演算法求解分區邊界，原因在於本研究的 MG 分區屬於訓練前即固定的代理人管轄範圍設計，目的是為 DTDE 多代理人架構提供穩定的局部觀測與決策邊界，而非如前述文獻中將分區本身視為孤

島復電時的動態決策變數。完整的 IEEE 123-bus 饋線在 pandapower 建模中共包含 130 個匯流排，各 MG 的管轄節點數分別為 MG0：22、MG1：37、MG2：20、MG3：25、MG4：26，總和為 130。分區邊界依地理分區與電氣拓撲特性劃定，各 MG 代理人依其管轄範圍執行獨立的 ESS 調度與開關控制決策。

在此分區架構下，本研究進一步區分關鍵負載與一般負載，這一處理方式呼應了配電系統復電文獻中常見的負載優先權機制：負載依其對維持社會關鍵功能的重要性而被賦予不同優先序，例如醫療設施在復電順序上理應優先於非必要的商業用電；部分文獻更進一步為關鍵負載設定可容忍的最大停電時長，作為復電排程必須滿足的硬性約束，而非單純的軟性權重。本研究依循此概念，將部分負載節點標記為關鍵負載，於獎勵函數中賦予較高的復電優先權重，並將這些關鍵負載分布於不同的 MG 管轄範圍，而非集中於單一 MG，確保多代理人系統的訓練目標涵蓋跨 MG 範圍的整體復電品質，避免代理人僅學會優化自身管轄範圍內的局部利益。

4.3.3 DER 配置設計與 ESS 容量分析

在 IEEE 123-bus 這類徑向配電網路中，若 DER 部署位置與負載集中區域距離較遠，功率須經過較長的線路路徑才能傳輸至高負載節點，這會增加線路損耗並加劇沿線電壓降，在重負載時段更容易使電壓跌出允許範圍。因此，本研究設定各 MG 的 DER 配置遵循統一規則：在該 MG 管轄範圍內找出具有最高有功負載需求的節點，並在此節點集中部署所有 DER 設備，縮短功率傳輸的路徑距離，降低線路損耗並減輕電壓降的影響。

本研究設定各 DER 容量倍數的設定原則如下

- PV 峰值出力 $1.5 \times P_{load,mg}$ ：

PV 的額定容量是面板在標準測試條件下的理論上限，但實際出力隨日照角度與時間持續變化，多數時段的實際出力遠低於額定值，若僅依負載量設定 PV 容量，僅有日照最強的少數時段能覆蓋負載，其餘時段將出現供電缺口。因此，本

研究將 PV 容量設為該 MG 總有功負載的 1.5 倍，確保白天大部分時段的實際出力仍足以覆蓋負載並為 ESS 充電，同時留有裕度以應對 $\pm 5\%$ 的天候擾動。這一作法對應實務上配電系統規劃時常見的考量：DER 的額定容量規劃通常需高於其服務對象的負載需求，以彌補額定值與實際出力之間的落差。

- ESS 充放電功率額定值 $0.8 \times P_{load,mg}$ ：

若 ESS 額定功率設為與總負載等量，當 ESS 同時以額定功率運行時，可能在配電網路中造成電壓超出允許範圍 0.95-1.05 p.u. 的過電壓問題；此外，若單一 ESS 的功率餘裕過大，代理人可能僅依賴自身管轄範圍內的 ESS 即可解決局部供需失衡，無須仰賴跨 MG 的能量協調，這將削弱本研究多代理人協調機制原本設計用以驗證的跨代理人協調必要性。因此，本研究將 ESS 功率額定值設為總負載的 80%，略低於總負載以同時降低過電壓風險並保留跨 MG 協調的必要性，此數值仍足以在夜間無 PV 出力提供主要的負載供電能力。此設計也反映了配電系統中常見的現象：管轄範圍內各負載節點極少同時達到各自的尖峰需求，供電設備的額定容量通常依據實際同時發生的尖峰負載設定，而非各節點尖峰需求的直接加總。

- ESS 能量容量 $7.0 \times P_{load,mg}$ ：

ESS 需同時滿足兩項時序需求：白天必須能在 PV 出力期間內完成充電，夜間則須在無 PV 出力的情況下持續供電，兩者對容量的需求方向不同，須一併考量才能確定合理的容量數值。因此，本研究將 ESS 能量容量設定為總負載的 7.0 倍，與 0.8 倍的功率額定值相除約為 8.75 小時，對應跨夜供電所需的持續時間。這一設定方式對應實務上孤島運行容量規劃的常見考量：容量需依據最長預期的孤島持續時間設定，過小無法支撐完整的供電缺口，過大則造成容量過剩。白天充電可行性分析詳述如下；夜間能量需求與跨 MG 協調的定量分析詳見第 2.1 節。

- STATCOM 虛功容量 $\pm 0.96 \times P_{load,mg}$ [MVAR]：

ESS 逆變器的視在功率額定值為固定上限，若逆變器需同時供應有功與無功，無功需求將壓縮有功的可用輸出空間，導致逆變器因視在功率超出額定而限制有功輸出。孤島運行下，無功負載的變動會直接造成電壓波動，若僅依賴 ESS 逆變器同時兼顧有功供電與無功補償，將難以同時滿足兩者的需求。因此，本研究另外設置 STATCOM 獨立負責孤島內的無功補償，使 ESS 逆變器的額定容量得以完全保留給有功輸出。

STATCOM 最大虛功容量設定為 $Q_{\text{STATCOM}} = 1.2 \times P_{\text{ESS}} = 0.96 \times P_{\text{load,mg}}$ ，此設定值從兩個面向提供足夠的無功補償裕度：其一，配電系統的感性負載在典型運行條件下產生的無功需求約為有功負載的 0.6 至 0.8 倍， $0.96 P_{\text{load}}$ 的容量能在負載功率因數低至 0.72 時仍完整補償無功缺口；其二，本研究 PV 容量設定為 $1.5 P_{\text{load}}$ ，在日照峰值時段 PV 大量有功注入可能導致孤島電壓升高，STATCOM 需以感性模式吸收無功以抑制過電壓， $0.96 P_{\text{load}}$ 的容量足以覆蓋此場景的感性補償需求。

- 白天充電可行性分析

本研究採用的負載曲線與 PV 出力曲線如下：

$$\text{pv_profile}[h] = \max\left(\sin\left(\frac{(h-6)\pi}{12}\right), 0\right) \quad (4.5)$$

$$\text{load_profile}[h] = 0.5 + 0.3e^{-\frac{(h-14)^2}{8}} + 0.2e^{-\frac{(h-20)^2}{4.5}} \quad (4.6)$$

在基準條件無隨機擾動、初始 SOC = 50% 下，白天（07:00–17:00）PV 有效出力期間， $1.5 \times P_{\text{load}}$ 的 PV 出力扣除負載需求後，有淨剩餘的時段為 08:00–16:00，剩餘能量總計為 $4.763 \times P_{\text{load}}$ ，超出從 50% 充滿至 100% 所需能量約 36%，理論上可在 08:00–13:00 的 5 小時內完成充滿。

然而，白天能否充滿至 100% 是條件式的結果，而非保證，取決於以下因素的組合：

- ◆ 初始 SOC 的隨機性：訓練環境中初始 SOC 在 40%–60% 之間均勻隨機抽取。當初始 SOC 為 40% 時，需充入 $4.2 \times P_{\text{load}}$ 才能達到 100%，與白天 PV 剩餘總量之間的

充裕空間縮小至約 13%。

- ◆ 早期充放電決策的影響：若代理人在白天 PV 出力充裕的早期時段（06:00–09:00）因判斷孤島內停電而選擇放電，SOC 可能在充電有效時窗開始前進一步下降，使充滿所需時間從理論的 5 小時延長至接近充電時窗的上限。在 SOC 跌至 15%–20% 的極端情況下，白天剩餘的 PV 能量恰好足夠但幾乎無誤差容忍空間。
- ◆ PV 出力的隨機擾動：每步 $\pm 5\%$ 的均勻分佈擾動在最壞情況下可將 PV 剩餘總量從 $4.763 \times P_{load}$ 降至約 $4.52 \times P_{load}$ 。若此與低初始 SOC 及早期放電失誤同時發生，累積壓力可能使充電目標無法達成。

4.3.4 STATCOM 建模方式

STATCOM（靜態同步補償器）在潮流計算中以 PV 節點方式建模：有功輸出設為零，即純虛功補償設備，電壓設定點 1.0 p.u.，虛功範圍設為 $\pm Q_{STATCOM}$ 。PV 節點建模的物理意涵是：潮流求解器在每次牛頓-拉夫遜迭代中，將 STATCOM 節點的電壓幅值與有功視為已知量，並將虛功輸出作為待求變數，在每次迭代中自動求解出使電壓維持在設定點所需的無功量，只要求解結果落在 $\pm Q_{STATCOM}$ 的容量限制內，STATCOM 便能對該節點實現精確的電壓調節。

此建模方式有效支撐孤島區域的電壓維持：在輕負載或 PV 大量出力的場景下，線路末端電壓傾向升高，STATCOM 吸收多餘的無功以抑制電壓過高；在重負載或夜間 PV 無出力的場景下，線路壓降增大導致電壓跌落，STATCOM 注入無功以支撐電壓回升，緩解 ESS 逆變器因同時輸出大量有功與無功而超出視在功率額定的問題。

4.3.5 任務難度的多維結構

綜合上述分析，本研究訓練環境的任務難度來自多個互相交織的維度如表 4.3 整理所示，而非單一的能量約束：

- 能量管理與拓撲控制的聯合最優化：即使 ESS 能量充足，若代理人在關鍵時步作

出錯誤的開關投切決策，ESS 的放電能量只能流向已連通的部分節點，其餘節點即使鄰近 ESS 也因拓樸孤立而無法接受供電。Chen et al.與 Lei et al.的微電網形成最佳化模型中，節點能否接收電源供電的入流功率約束直接取決於該節點是否被開關決策納入對應的拓樸子樹，即使對應電源容量充足亦然，這一約束結構說明拓樸決策與能量決策本質上無法獨立最佳化。本研究將此靜態最佳化問題延伸至動態序列決策場景：代理人在關鍵時步的拓樸誤判會持續限制後續時步的供電可行域，提升 ESS 容量並無助於解決拓樸決策失誤。

- AND 投票機制的跨 MG 協調挑戰：跨 MG 的 Tie-line 投切採用 AND 投票機制，意即雙端均輸出正值才實際連通，可防止單方面決策造成的物理違規，但也引入了跨代理人協調失敗的可能性。當兩個 MG 的代理人基於各自的局部觀測作出相反的 Tie-line 決策時，AND 投票即告失敗，能量無法跨 MG 流通。此類協調失敗在分散式局部觀測架構下是結構性存在的，需要 PC 共識機制在參數層面拉近各 MG 代理人的決策傾向，以提升跨步協調的一致性。

表 4.3 訓練環境難度來源與對應架構設計

難度來源	說明	對應架構設計
初始 SOC 隨機性	每 episode 起點不同，充電壓力不確定	GRU 記憶 SOC 趨勢
早期決策的 跨步累積效應	前幾步的次優決策影響後續 12+步	BPTT 序列訓練
夜間能量缺口	單 MG 不足，需跨 MG 協調	PC 共識與 GNN 鄰居感知
能量管理與 拓樸控制聯合優化	開關決策與充放電決策相互影響	連續動作空間與 TD3 訓練穩定性

AND 投票協調失敗	局部觀測下的跨 MG 意圖不一致	PC 共識校正策略方向
PV 與負載的 隨機擾動	每步 $\pm 5\%$ 的不確定性	POMDP 建模與 GRU 記憶

比較分析實驗結果詳見第五章顯示，在隨機初始 SOC 條件下，缺乏 TD3 三項改進的 DDPG 架構無法收斂的狀況下，直接量化了上述多維挑戰在隨機條件下對訓練穩定性的影響。

4.4 MicrogridEnv 環境模組

IEEE123_DTDE_Env 類別整合 PandaPower 電力計算引擎、NetworkX 圖論孤島偵測、Virtual Slack 動態指派、多代理人 AND 投票 Tie-line 協調以及 15 項複合獎勵計算等核心功能，是本研究演算法訓練與評估的物理現實模擬器。

4.4.1 Gym 環境介面

環境基於 OpenAI Gym 框架開發，實現 `reset()`、`step(actions)` 兩個核心方法，並定義觀測空間與動作空間屬性。

各代理人 i 的觀測空間定義為連續向量空間，觀測向量中各特徵均依其物理量綱各自正規化，以確保神經網路輸入各維度的數值量級一致，避免量綱差異主導梯度更新。由於各代理人管轄的匯流排數量與 ESS 數量不同，各 MG 的實際觀測維度依管轄匯流排數、開關線路數與鄰居數而異，統一補零至系統中的最大觀測維度，由於分區邊界在訓練期間固定，各代理人的補零模式恆定，網路在訓練過程中可穩定學習忽略填充位置，無需額外的有效性遮罩機制。動作空間定義為連續向量空間，各維度範圍均為 $[-1, +1]$ ，由代理人的開關控制維度 n_{sw}^i 維與 ESS 充放電控制維度 n_{ess}^i 維串接組成。

4.4.2 局部觀測向量結構

各代理人 i 的未補零觀測向量由以下區塊依序串接組成，各區塊的詳細內容與正規化方式如表 4.4

表 4.4 局部觀測向量各區塊結構

觀測區塊	每單元維度	內容說明與正規化
時間特徵	1	$\frac{t \bmod 24}{24}$ ，24 小時週期正規化
每個匯流排	6	$\left(V-1, \frac{P_{\text{load}}}{S_{\text{base}}}, \frac{Q_{\text{load}}}{S_{\text{base}}}, \text{is_crit}, \text{PV}^{\text{exp}}, \frac{\text{SOC}-50}{50} \right)$; 無 ESS 時 SOC 填-1
每條開關線路	2	$\left(\text{status} \in \{+1, -1\}, \frac{P_{\text{line}}}{S_{\text{base}}} \right)$ ，+1 表示閉合，-1 表示斷開
Episode 進度	1	$1 - \frac{\max(0, t - t_{\text{start}})}{T_{\text{max}}}$ ，剩餘時間比例
每個 ESS	5	$\left(\frac{\Delta \text{SOC}}{100}, \text{is_slack} \in \{+1, -1\}, \frac{E_{\text{left}}}{P_{\text{max}} \times 12}, \right.$ $\left. \text{can_discharge} \in \{+1, -1\}, \text{can_charge} \in \{+1, -1\} \right)$
上一步 ESS 動作	1	上一步實際輸出的 ESS 控制量
停電比例	1	本 MG 停電匯流排數/本 MG 總匯流排數
鄰居平均 SOC	$ \mathcal{N}_i $	$(\text{SOC}_{nb} - 50) / 50$ ，clip 至 $[-1, +1]$ ； 僅為聚合標量，無法觀測鄰居完整狀態

觀測向量的 ESS 區塊第二維中 is_slack 特徵是一個關鍵的設計細節：當某個 ESS 被系統動態指派為當前孤島的 Virtual Slack 時，其值為+1，否則為-1。此設計使代理人能夠間接感知系統的功率平衡參考點位置，從而在決策時避免對已承擔調頻職責的 Virtual Slack ESS 過度充放電，有助於維護系統電壓穩定。

鄰居平均 SOC 的觀測設計體現了 DTDE 框架下的有限通訊原則：代理人 i 不知曉鄰居的完整觀測向量，僅能獲取鄰居 MG 內所有 ESS 的 SOC 均值的一個聚合的標量資訊，既提供了跨 MG 的能量狀態感知，又不洩漏鄰居的詳細拓樸或動作資訊。

4.4.3 環境初始化 (reset)

每個訓練回合開始時呼叫重置方法，對環境進行初始化。起始時刻固定為 06:00，最大步數 $T_{\max} = 24$ ，對應 24 小時操作週期，每步代表 1 小時的控制週期。初始化時所有可切換線路均設為斷開，外部電源連線切除，系統以孤島模式啟動；各 MG 之間透過非切換線路維持的電氣連接仍然存在，形成初始的連通拓樸，模擬災後逐步恢復的過程。

本研究 ESS 初始化方式有兩種：固定 SOC 場景下，所 ESS 的初始電量狀態統一設為 50%；隨機 SOC 場景下，各 ESS 的初始電量狀態從均勻分佈 [40%, 60%] 中獨立取樣。初始化後立即執行一次潮流計算，獲取系統初始電氣狀態，作為代理人在第一個時間步的觀測向量輸入。

4.4.4 Virtual Slack 動態指派機制

在微電網孤島化情境下，外部電源連接已斷開，每個孤島需要獨立指定一個 Slack 參考節點承擔有功功率平衡與電壓相角基準的功能，才能使潮流方程組有唯一解。本研究設計 Virtual Slack 動態指派機制：在每次執行潮流計算之前，系統自動掃描當前孤島 C_m 內所有 SOC 超過 5% 的 ESS 節點，選取剩餘電量 $SOC \times E_{cap}$ 最高的 ESS 匯流排作為該孤島的 Virtual Slack：

$$v_{\text{slack},m}^* = \arg \max_{\substack{v_i \in \text{ESS}(C_m) \\ \text{SOC}_i > 5\%}} \left(\text{SOC}_{i,t} \times E_{\text{cap},i} \right) \quad (4.7)$$

SOC 下限保護 5% 確保被指派為 Virtual Slack 的節點具備足夠的調節裕度，避免近乎耗盡的 ESS 承擔調頻職責導致孤島電壓崩潰。

被選為 Virtual Slack 的 ESS 以外部電源節點方式建模，承擔孤島內的功率平衡補償。為反映真實逆變器的視在功率限制，Virtual Slack 的虛功輸出範圍設定為：

$$Q_{\max} = \sqrt{S^2 - P^2} = \sqrt{1.25^2 - 1.0^2} \times P_{\text{rated}} = 0.75 \times P_{\text{rated}} [\text{MVAR}] \quad (4.8)$$

此限制來自逆變器視在功率額定值 $S = 1.25 \times P_{\text{rated}}$ ，對應額定功率因數 $P/S = 0.8$ ，因此最大無功輸出 $0.75 \times P_{\text{rated}} [\text{MVAR}]$ 。此設計消除了假設 Slack 節點可無限補償無功所導致的電壓失真，使電壓模擬更接近真實逆變器行為。

此動態選取策略具有雙重優勢：SOC 最高的 ESS 具備最大的調節裕度，其既可吸收過剩功率充電，也可釋放電量補充供電缺口，作為 Slack 節點具備最強的系統穩定能力；同時，此設計自然地引導代理人優先保持較高的 SOC 以維持競選 Virtual Slack 的資格，形成隱性的 SOC 保護動機。代理人透過觀測向量中各 ESS 的 is_slack 標誌間接感知平衡點位置，而無法直接控制指派結果，構成 POMDP 架構中的部分可觀測資訊之一。

4.4.5 動作執行與約束驗證

step 方法接收所有代理人的聯合動作字典，執行以下完整的物理驗證與狀態更新流程。

第一步. 動作解碼：對各代理人的連續動作向量 $a_{i,t} \in [-1, +1]^{d_i}$ 進行解碼，開關控制量

x^{sw} 透過閾值判斷生成投切建議， $x > 0$ 表示投閉建議， $x \leq 0$ 表示分開建議，ESS

功率控制量 a^{ess} 線性映射至 $\left[-P_{\text{ess}}^{\max}, +P_{\text{ess}}^{\max}\right]$ ，其正值為充電，負值為放電。

第二步. AND 投票：對所有跨 MG Tie-line 依匯流排所屬 MG 的物理隸屬關係判斷執行雙端 AND 投票，僅當連接兩端的代理人均輸出投閉建議 $x > 0$ 時，該 Tie-line 才實際閉合，否則保持或切換至斷開狀態，更新電網鄰接矩陣 A_t 。

第三步. 孤島偵測與 Virtual Slack 指派：依據更新後的拓撲圖進行連通分量分析，為各孤島依式 4.7 動態指派 Virtual Slack，建立對應的功率平衡參考節點。若某孤島內

無 SOC 超過 5% 的 ESS，該孤島內所有匯流排及負載直接標記為停電，不進行潮流計算。

第四步. ESS 設定：將各 ESS 的充放電功率目標值設定至電力模擬模型。代理人的

ESS 控制量 $a^{ess} \in [-1, +1]$ 線性映射至實際功率設定值 $p = a^{ess} \times P_{ess}^{max}$ 正值代表充電、負值代表放電。在寫入模型前，先依 SOC 邊界進行硬性裁剪：當 SOC 已達 0% 時強制取消放電指令，當 SOC 已達 100% 時強制取消充電指令，確保 ESS 不會因代理人指令越界而出現物理不可行的充放電行為。裁剪後的功率值作為實際有功注入量寫入潮流模型，參與後續的潮流計算。

第五步. 潮流計算與約束驗證：執行潮流計算。若收斂成功，提取各匯流排電壓 $|V_i|$ ，

驗證電壓約束 $0.95 \leq |V_i| \leq 1.05 \text{ p.u.}$ ；提取各支線與變壓器的視在功率流 $|S_{ij}|$ ，驗證容量約束 $|S_{ij}| \leq |S_{ij}^{max}|$ ；計算各違規比例 P_V 、 P_L 、 P_T 作為獎勵懲罰項的輸入。若潮流計算不收斂，直接回傳零獎勵，促使代理人學習維持電網可解狀態，避免因拓樸組合不當導致孤島內缺乏有效 Virtual Slack 而使潮流無法收斂。

第六步. SOC 更新：依據 ESS 的實際充放電功率與時間步長更新各 ESS 的電量狀態：

$$\text{SOC}_{i,t+1} = \text{SOC}_{i,t} + \frac{p \cdot \Delta t}{E_{cap}} \times 100\% \quad (4.9)$$

其中 $p > 0$ 為充電、 $p < 0$ 為放電，確保 $\text{SOC} \in [0\%, 100\%]$ 。

4.4.6 獎勵函數設計

微電網群復電任務涉及拓樸控制、能量管理、電氣品質與跨 MG 協調等多個相互耦合的子目標，單一獎勵訊號難以同時引導代理人在這些維度上做出平衡決策。因此，本研究設計由 15 項加權指標組成的複合獎勵函數整理如表 4.5 所示，從任務完成、電氣品質、資源管理與系統安全四個維度引導代理人策略，各項指標的權重設計反映其對整體復電目標的相對重要性。

表 4.5 複合獎勵函數設計

獎懲項目	獎懲說明
通電比例	本 MG 管轄範圍內成功供電的匯流排比例，鼓勵代理人盡可能恢復更大範圍的供電覆蓋。
局部關鍵復電	對本 MG 管轄範圍內已復電的關鍵負載給予正向獎勵，對尚未復電的關鍵負載施加懲罰，驅動代理人優先保障關鍵負載供電。
整體恢復獎勵 (線性)	依全系統已復電關鍵負載數占總數的比例給予獎勵，使各代理人的優化方向收斂於整體系統的復電目標，而非僅關注自身管轄範圍
整體恢復獎勵 (完美加成)	當全部三個關鍵負載同時復電時給予額外獎勵，強化代理人在跨 MG 協調下達成完整復電的動機。
電壓品質	對已供電匯流排的平均電壓偏離 1.0 p.u.的程度給予連續性獎勵，引導代理人在不違規的前提下進一步維持電壓穩定，補充違規懲罰硬性違規懲罰所無法提供的細緻梯度信號。
違規懲罰	對電壓越限、線路過載、變壓器過載三類物理違規分別施加懲罰，懲罰強度依違規程度線性計算，促使代理人學習維持電網在安全運行邊界內。
夜間 SOC 保留	夜間時段 (18:00–05:00) 依 ESS 平均 SOC 與剩餘夜間時數給予獎勵，越晚且 SOC 越高獎勵越大，引導代理人在夜間盡量保留電量以應對後續供電缺口。
白天充電鼓勵	白天充電時段 (08:00–16:00) 依 ESS SOC 相較上一步的增量給予獎勵，鼓勵代理人在 PV 出力充裕時積極充電，為夜間供電預備能量。
前瞻 ESS coverage	評估 ESS 剩餘電量能否覆蓋後續步驟的預期夜間供電缺口，coverage 越低懲罰越重，分段非線性設計使代理人在 SOC 臨近臨界值時受到強烈的保守化引導。

夜間 Tie 接受方 鼓勵	夜間自身 SOC 偏低時，若已有一條連接到 SOC 更高鄰居的 Tie-line 開通，給予正向獎勵，確保低電量 MG 的代理人有足夠動機投票開通 Tie-line 以接受跨 MG 能量支援。
夜間 Tie 提供方 鼓勵	夜間高 SOC 代理人透過已開通 Tie-line 向低 SOC 鄰居提供能量時給予獎勵，與夜間 Tie 接受方鼓勵共同形成 AND 投票機制下的雙端協調激勵
Virtual Slack 過 載	當 Virtual Slack ESS 的視在功率輸出超出逆變器額定值時施加懲罰，避免代理人過度依賴 Slack 節點的功率平衡補償能力
線路損耗	對不必要的線路損耗施加懲罰，引導代理人減少低效的功率迴路，提升整體系統的能源利用效率
雙 VS 封閉迴路	當兩個 Virtual Slack 節點因 Tie-line 投切形成封閉迴路時均等施加懲罰，防止多 Slack 共存於同一孤島導致潮流計算失真
停電懲罰	對本 MG 管轄範圍內的停電匯流排比例施加強化懲罰，作為通電比例獎勵的反向補充，在停電狀態下產生更強烈的恢復供電驅動力

前瞻 ESS coverage 是獎勵函數中設計最為精細的一項，用於評估各 ESS 在後續時間步中的供電保障能力：

$$\text{cov}_k = \frac{E_{\text{left},k}}{\max\left(\sum_{s=t}^{T-1} \min\left(\max(L_s - PV_s^{\text{exp}}, 0), P_{\text{ess},k}^{\max}\right) \cdot \Delta t, 10^{-4}\right)} \quad (4.10)$$

分子 $E_{\text{left},k}$ 為 E_k 的當前剩餘電量 (MWh)，分母為後續每步的預期淨需求，為負載需求超過 PV 預測出力的部分，並以 ESS 最大功率截斷的累計值。此指標使代理人在每步決策時考量自身 ESS 是否有足夠的剩餘電量應對後續的夜間供電缺口。coverage 指標的非線性懲罰設計為分段函數，coverage 越低懲罰越重，使代理人在 SOC 充裕時有較大的行動自由，而在 SOC 臨近臨界閾值時得到強烈的保守化引導。 PV_s^{exp} 使用動態計算的 PV 容量比例乘以對應時段的 PV 預測值，而非實際擾動後的出力值，確保不洩漏

未來的隨機資訊，符合 POMDP 的資訊約束要求。

4.5 訓練流程

本節完整描述 DTDE-PC-Memory-TD3 的訓練流程，包括序列訓練 BPTT 的三階段結構、探索噪聲排程、Anti-stagnation 機制、崩潰恢復邏輯與完美收斂判定準則。表 4.6 列出完整的超參數設定，Algorithm 以偽程式碼形式整理本論文所提出之復電強化學習訓練架構。

4.5.1 序列訓練結構

本研究的 Actor 與 Critic 均內建 GRU 記憶模組，代理人在執行階段透過 GRU 跨時步累積觀測歷史，形成對環境狀態的內部記憶。然而這也引入了一個訓練問題：GRU 的隱狀態 h_t 由前序觀測序列決定，若訓練時每次從回放緩衝區隨機抽取單步資料並以零向量初始化隱狀態，網路在訓練時所使用的記憶內容將與執行時的實際記憶內容完全不符，導致訓練環境與執行環境之間的記憶狀態不一致，削弱 GRU 的時序整合能力。

因此，本研究採用 burn-in 序列訓練策略[30]，以 $b=4$ 步 burn-in 暖機隱狀態後，對剩餘 $T-b=20$ 個有效時步執行完整的時序反向傳播（BPTT）確保 GRU 在訓練時能夠沿完整時序依序更新隱狀態，重現執行時的記憶累積過程。每次參數更新從雙池經驗緩衝區抽取 $B=16$ 個 Episode 序列維度： $B \times T \times d$ ，執行以下三階段訓練流程。：

一、Burn-in 暖機階段 $t \in [0, b)$ 為序列時間步索引， $b = \min(4, T-1)$ 取 min 確保 burn-in

步數不超過序列長度，無梯度計算：即使採用完整 Episode 序列訓練，隱狀態仍必須從某個初始值開始，若直接從零向量起步執行梯度計算，序列前段的隱狀態尚未累積足夠觀測歷史，以此為基礎計算的梯度方向不可靠，會引入與策略學習無關的雜訊。因此，Phase 1 以零初始隱狀態為起點，依序對所有網路雙 Critic 網路、目標網路、Actor 網路在不累積梯度的情況下逐步更新 GRU 隱狀態，使隱狀

態在進入梯度計算階段前已累積了前 b 步的觀測記憶。Burn-in 結束後對所有隱狀態執行梯度截斷，切斷暖機階段與後續更新階段之間的梯度連接。

二、Critic 更新階段 $t \in [b, T)$ ，有效步數 $t \in n_{train} = T - b = 20$ ，執行梯度計算：Critic 的訓練目標是準確估計每個狀態-動作對的長期價值，但單一 Critic 在高方差環境下容易高估 Q 值，導致 Actor 在訓練過程中追逐不真實的高分動作。因此，Phase 2 對每個有效時步 t 先以 Actor 目標網路依目標策略平滑化式 3.13 對下一狀態的動作加入截斷高斯雜訊，再依式 3.10 計算 TD 目標值 y ；TD3 路徑取雙 Critic 目標網路 Q 值的最小值作為保守估計，DDPG 路徑則取單 Critic 目標值。接著以 Smooth L1 損失式 3.11 計算雙 Critic 的預測誤差，損失在 n_{train} 個有效時步上平均後反向傳播，再梯度裁剪後執行參數更新。DDPG 比較路徑僅更新單 Critic，無目標策略平滑化。

三、Actor 更新階段為 2 次 Critic 更新執行一次：Actor 的訓練方向來自 Critic 的 Q 值估計，若 Actor 與 Critic 同頻更新，每次 Critic 剛完成一次更新、估計尚未穩定，Actor 就立即依此調整策略，容易放大 Q 值估計誤差對策略的影響。因此，Actor 採用延遲更新設計，每累積 2 次 Critic 更新才執行一次 Actor 更新，使 Critic 有足夠的更新次數收斂至較穩定的估計後，再以 Critic 1 的 Q 值估計為目標，依式 3.12 計算 Actor 損失，梯度裁剪後執行參數更新。Actor 更新完成後立即對雙 Critic 與 Actor 目標網路執行軟更新，將主網路參數緩慢混入目標網路以維持訓練穩定性。

4.5.2 探索噪聲與訓練穩定機制

強化學習訓練初期需要足夠的探索能力才能發現有效的復電策略，但訓練後期過大的探索噪聲會干擾已收斂的策略執行確定性動作。因此，探索噪聲標準差 σ_{base} 採用線性衰減策略，隨訓練回合數逐漸降低：

$$\sigma_{base}(ep) = \max\left(0.05, 0.30 - \frac{ep}{5000} \times 0.25\right) \quad (4.11)$$

衰減係數與最大訓練回合數 5000 一致，使探索噪聲在訓練全程從 0.30 線性衰減至下限

0.05，確保訓練初期具備充分的探索能力，後期則逐步收斂至最低噪聲水準以穩定策略執行。

線性衰減能應對正常的訓練進展，但無法應對策略已有效收斂後卻因參數更新累積誤差而急劇退化的崩潰情況。因此，本研究設計崩潰恢復機制：每次評估完成後，若同時滿足以下四項條件：當次評估 GoodAvg 低於歷史最佳的 60%、歷史最佳 GoodAvg 大於 18.0 為確保存在有意義的恢復基準、歷史最佳評估曾至少成功復電一個關鍵負載、且為防止連續觸發，設計距上次崩潰恢復超過 400 回合——系統自動載入歷史最佳策略參數，並同步還原對應的精英回放緩衝區，確保後續訓練所使用的精英序列與恢復的策略品質一致。

恢復後的噪聲策略依歷史最佳品質決定：若歷史最佳 GoodAvg 大於等於 24.0，策略已達完美水準，直接恢復而不加噪聲增強，避免破壞已收斂的確定性策略；若歷史最佳 GoodAvg 小於 24.0，策略尚未達到完美水準，恢復後觸發 300 回合的噪聲增強，重新激活探索能力。崩潰恢復觸發時，實際探索噪聲上限截斷確保增強後的噪聲水準不超過訓練初始值 0.30。

4.5.3 完美收斂判定與四輪確認機制

訓練收斂的判定需要同時滿足多個維度的標準，單次評估高分並不足以作為可靠的收斂依據，因為探索噪聲或隨機初始 SOC 的偶然組合可能造成暫時性高分，而策略本身並未真正穩定。因此，本研究設計完美收斂判定機制，要求評估結果同時通過四項指標，且訓練過程中累計出現的 Good=24 Episode 數量達到 10 筆以上，確保末步 SOC 標準差的均值計算具備足夠的統計基礎才啟動判定：

1. $\text{GoodAvg} \geq 24.0$ ：30 個評估 Episode 的平均每步完成任務時間步數與恢復關鍵負載數達到最大值，即所有評估 Episode 均在每一步維持完整供電。
2. $\sigma_R < 20.0$ ：30 個評估 Episode 間的原始獎勵標準差低於 20.0，確保策略在不同初始條件下表現穩定，而非僅在部分隨機種子下偶發高分。

3. $8.0 \leq \overline{\text{SOC_std}}$: Good=24 Episode 的末步 SOC 標準差均值下限 8.0 排除各 MG

ESS 過度均一的情況，此狀況避免代理人學會了同時放電的情形而非真正最優的跨 MG 協調機制，缺乏保留電力協調，

4. $\overline{\text{SOC_std}} \leq 20.0$: Good=24 Episode 的末步 SOC 標準差均值上限 20.0 排除各 MG

SOC 嚴重失衡的情況。此狀況可能代表部分 MG 過度放電而另一部分閒置。

即使單次通過上述四項指標，策略仍可能因評估隨機性而在後續評估中退步。因此採用四輪連續確認機制：第一次通過後進入策略凍結確認模式，凍結所有網路參數更新、設定探索噪聲為零強制確定性滾出、策略共識永久鎖定，確保後續三次評估完全反映已凍結策略的真實泛化能力；第二、三次評估若持續通過則維持凍結模式；任一次評估未通過則解除凍結，恢復正常訓練；第四次確認通過後系統觸發訓練終止程序，輸出最終策略。

每 500 回合執行一次評估，執行 30 個確定性 Episode 統計上述指標，確保判定基於足夠的樣本數量。此設計確保輸出的最終策略在四次獨立評估中均達到完美標準，有效排除偶發性高分的干擾。

4.5.4 主要超參數設定與訓練流程整合

表 4.6 彙整 DTDE-PC-Memory-TD3 訓練過程的全部主要超參數，供實驗可重現性參考。

表 4.6 主要超參數設定

超參數	數值	說明
d_{hidden}	128	GRU / Actor / Critic 隱藏層統一維度
η_{actor}	1×10^{-4}	Actor 優化器學習率
η_{critic}	3×10^{-4}	Critic 優化器學習率
權重衰減	1×10^{-4}	L2 正則化係數

梯度裁剪 (Actor / Critic)	0.5 / 0.5	梯度裁剪上限
折扣因子 γ	0.99	重視 24 步全程的長期獎勵
目標網路軟更新係數 τ	0.005	目標網路緩慢同步
PC 後快速同步 τ_{fast}	0.02	PC 共識後主網路參數跳至加權平均值，若不同步目標網路將導致 Bellman 目標暫時失準，故以 4 倍 τ 加速追上
目標策略噪聲 σ_{policy} / 截斷	0.2 / 0.5	TD3 目標策略平滑化噪聲標準差/截斷範圍
Actor 延遲更新週期 d_{policy}	TD3: 2 / DDPG: 1	TD3 每 2 次 Critic 更新執行 1 次 Actor 更新
Burn-in 長度 b	4	BPTT 暖機步數
GNN 自連結權重 a_{self}	0.6	依 GNN 架構比較分析實驗選定
PC Actor 自身保留係數 w_{actor}	0.8	Actor 共識時保留自身權重，低於 w_{critic} 以允許 Actor 策略方向更快向鄰居靠攏
PC Critic 自身保留係數 w_{critic}	0.85	Critic 保留係數高於 Actor，因 Critic 的 Q 值估計是 Actor 更新基礎，過快同步鄰居 Critic 會引入不一致的價值估計
策略共識週期 f_{pc}	15ep	固定週期執行策略共識
連勝鎖最大持續時間	300ep	PC StreakLock 最大持續時間，超時強制解鎖以防止策略共識長期停用導致代理人參數漂移
普通池/精英池容量	2000 / 500 ep	先進先出緩衝
精英池取樣比例	0.25	訓練全程固定，不隨進度調整

批次大小 B	16	每次更新抽取的 Episode 數
每回合網路更新次數	4	每 Episode 結束後執行的參數更新次數
最大訓練回合數	5000ep	可依需求調整
暖機回合數	50ep	僅執行滾出，不進行參數更新
評估週期	500ep	每次執行 30 個確定性 Episode
σ_{base} 初始值/下限	0.30 / 0.05	探索噪聲線性衰減範圍
崩潰恢復增強量	+0.05/300ep	歷史最佳 GoodAvg<24 時觸發
Episode 最大步數 T	24	對應 24 小時復電週期

Algorithm 以偽程式碼形式整合 4.5 節各子節描述的訓練機制，呈現 PC-Memory-TD3 的完整訓練流程。整體架構以 Episode 為外迴圈，每個 Episode 包含完整的 24 步、經驗緩衝區更新、梯度更新、PC 共識同步與評估確認五個階段，各機制的具體設計與超參數詳見各對應子節。

Algorithm: Training Procedure for PC-Memory-TD3

- 1 : Initialize Actor, dual-Critic, and corresponding target networks for each agent
- 2 : Initialize normal replay buffer and elite replay buffer for each agent
- 3 : Initialize exploration noise σ , running reward normalizer, convergence counter, and training flags
- 4 : for each training episode do
- 5 : Reset environment; initialize GRU hidden states $h \leftarrow 0$ for all networks and agents
- 6 : for each time step $t = 0, \dots, T-1$ do
- 7 : Each agent aggregates local and neighbor observations via GNN, updates hidden state via GRU, and selects action with exploration noise; clip ESS actions at SOC boundaries

```

8 :      Execute joint actions via AND-vote for cross-MG Tie-lines; observe next state and
        reward
9 :      Normalize reward via running statistics; store transition to buffer
10: end for
11: Evaluate elite criteria;
    store episode to normal buffer;
    if elite criteria met, also store to elite buffer
12: if episode  $\geq$  warm-up threshold and training not frozen then
13:     for each gradient update step do
14:         Sample shared indices from mixed buffer
15:         for each agent do
16:             Phase 1 — Burn-in: forward GRU for  $b=4$  steps without gradient to
                reconstruct  $h_b$ 
17:             Phase 2 — Critic update:
                    compute TD targets with target policy smoothing;
                    update dual-Critic with Smooth L1 loss;
18:             Phase 3 — Actor update every 2 Critic updates:
                    maximize Critic-1 Q-value;
                    soft-update all target networks
19:         end for
20:     end for
21: Update PC StreakLock state based on recent GoodAvg trajectory
22: if PC consensus interval reached and StreakLock inactive then
23:     Aggregate Actor and Critic parameters via weighted consensus over
        communication graph

```

```

24:         Fast-synchronize all target networks
25:     end if
26: end if
27: if evaluation interval reached then
28:     Run 30 deterministic episodes  $\sigma=0$ ; compute GoodAvg,  $\sigma_R$ , critical load
        Restoration,  $SOC_{std}$  metrics
29:     if all four convergence criteria satisfied then
30:         Freeze all network updates; lock PC consensus; set  $\sigma=0$ ; increment
            confirmation counter
31:         if confirmation counter = 4 then break end if
32:     else
33:         Unfreeze network updates; reset confirmation counter
34:     end if
35: end if
36: if performance collapse detected then restore best checkpoint and replay buffer end if
37:     Decay exploration noise
38: end for

```

第五章 模擬結果與分析

本章針對在 DTDE 框架下所提出之 PC-Memory-TD3 架構進行系統性比較分析，透過兩組控制實驗驗證各設計選擇的必要性，並以訓練收斂結果與代理人行為分析確認架構的整體有效性。

所有實驗均在 IEEE 123-bus 配電測試系統上執行如圖 5.1，系統劃分為 5 個微電網代理人，完整系統配置詳見第四章。所有訓練實驗均採用固定隨機種子以確保結果可重現，訓練回合數上限設為 5000 回合，每 500 回合執行一次包含 30 個確定性 Episode 噪聲 0 的評估，收斂判定採用四輪確認機制詳見第 4.5.3 節。

本章以 TD3+GRU 搭配策略共識，Actor 保留係數=0.8，Critic 保留係數=0.85，GNN 自身聚合比例 $a_{self}=0.6$ 為主方法基準，設計以下兩組比較分析：

- 一、記憶模組與演算法比較：比較 TD3+GRU、TD3+LSTM 與 DDPG+GRU 三種架構，分別在固定初始 SOC 50%與隨機初始 SOC [40%,60%]兩種環境條件下執行，驗證時序記憶模組 GRU、LSTM 與核心演算法骨架 TD3、DDPG 的獨立貢獻。
- 二、架構超參數比較：在隨機初始 SOC 條件下，對 PC 共識自身保留係數 0.7/0.7、0.8/0.8、0.9/0.9、0.8/0.85、noPC 及 GNN 自身/鄰居聚合比例 $a_{self}=0.2$ 至 1.0 進行系統性比較，驗證各架構設計選擇的必要性。各節詳細分析結果依序呈現於後。




圖 5.1 IEEE 123-bus 配電測試系統

5.1 評估指標定義

為便於後續結果呈現，本節正式定義各評估指標的計算方式與物理意義：

1. GoodAvg：30 個確定性評估 Episode 的平均每步完成任務時間步數，最高值為 24，對應 24 小時操作週期每步均維持完整供電。因 GoodAvg 的累計前提是每步同時滿足潮流收斂且三個關鍵負載全部復電，GoodAvg=24.0 等價於所有評估 Episode 在全部 24 步均達到完美復電。
2. G24%：30 個確定性評估 Episode 中 GoodAvg=24 的比例，直接反映策略在不同初始 SOC 條件下維持完美復電的一致性。G24%=100%代表所有 30 個 Episode 均達到完美復電，是進入四輪確認機制的必要條件之一。
3. 後 500ep 平均獎勵：訓練最後 500 回合的原始獎勵均值，反映策略在充分訓練後的穩定表現水準；其標準差反映策略輸出的一致性，數值越低代表策略在不同初

始條件下的表現越穩定。

4. 末步 SOC std：每回合第 24 步結束時各 MG ESS 電量狀態的標準差，衡量跨 MG 能量分配的均衡程度。由於本研究各 MG 的 ESS 容量均以各自負載為統一比例設計，在無跨 MG 協調的基準情況下各 MG 的 SOC 百分比變化完全相同，末步 SOC std 的大小因此直接反映策略是否執行了差異化的跨 MG 能量調度：SOC std 過低代表策略接近同步放電的無協調基準；SOC std 過高則代表部分 MG 能量嚴重耗盡而其餘閒置，能量分配失衡。SOC std 門檻的具體設計依據詳見第 4.5.3 節。
5. 收斂：通過四輪確認機制，訓練提前終止；未收斂代表達 5000 回合上限仍未通過四輪確認。

5.2 記憶模組與演算法之固定初始 SOC

本研究的 Group 1 比較分析分為兩個階段執行：本節先在固定初始 SOC=50%的穩定條件下建立三組架構的基準表現，5.3 節再引入隨機初始 SOC 條件進行泛化能力評估。兩階段設計的目的在於分離兩個不同的評估維度：固定 SOC 條件排除起始狀態不確定性的干擾，使三組架構在演算法層面的表現差異能直接被觀測；隨機 SOC 條件則進一步揭示各架構對初始狀態擾動的穩健性，表 5.1 彙整三組架構在固定初始 SOC 條件下的訓練結果，圖 5.2 圖 5.3 圖 5.4 分別為固定初始 SOC 之 24 小時訓練恢復曲線、Reward 曲線、SOC std 曲線。

表 5.1 固定初始 SOC 訓練結果彙整

方法	訓練回合數	後 500ep 平均獎勵	後 500ep GoodAvg	後 500ep SOC std	收斂
TD3+GRU	3500	4494.9±4.5	24.00	15.49	V
TD3+LSTM	5000	4539.8±88.6	23.56	9.43	X
DDPG+GRU	3000	4443.3±4.0	24.00	9.92	V

TD3+GRU 的評估 GoodAvg 呈現穩定的漸進式提升，從 ep500 的 22.23 逐步提升至 ep1500 的 23.87，並在 ep2000 首次同時通過 GoodAvg=24.00、 $\sigma_R=6.7$ 與 SOC std=15.3 三項收斂條件，進入第 1 輪確認。此後 ep2500 至 ep3500 連續三次評估結果完全相同，在 ep3500 完成第 4 輪確認，訓練收斂。收斂策略的末步 SOC std=15.3，處於 [8,20] 合理範圍，反映各 MG 之間的能量分配具備良好的差異化協調。

DDPG+GRU 呈現突破式收斂：ep1000 的評估 GoodAvg 雖達 23.00 但 G24%=0%，ep1500 評估 GoodAvg 直接達到 24.00、 $\sigma_R=3.8$ 與 SOC std=9.9，三項條件均通過，進入第 1 輪確認；此後三次評估結果完全相同，在 ep3000 完成第 4 輪確認。

DDPG+GRU 的收斂速度優於 TD3+GRU，說明在起始條件對稱且確定的環境下，單 Critic 架構不構成訓練障礙，甚至能更快地穩定收斂。

TD3+LSTM 的訓練過程揭示了一個特殊的失敗模式。ep1000 首次達到 GoodAvg=24.00 且 $\sigma_R=1.8$ ，進入第 1 輪確認；ep1500 評估結果完全相同，通過第 2 輪確認。然而 ep2000 的 GoodAvg 降至 23.27， σ_R 上升至 49.2，凍結策略在此輪未能通過，確認計數歸零，訓練恢復。值得注意的是，凍結策略的評估 SOC std=24.8 超過上限 20.0，反映策略雖能維持完美復電，但各 MG 之間的能量分配嚴重失衡。一旦凍結解除恢復訓練，策略品質在後續評估中反覆在 GoodAvg=20 至 23.8 之間劇烈波動，ep3000 深度崩潰至 GoodAvg=20.00，此後從未再次達到 G24%=100% 且 $\sigma_R < 20.0$ 同時成立的收斂條件，最終未能收斂。




圖 5.2 固定初始 SOC 之 24 小時恢復曲線




圖 5.3 固定初始 SOC 之 Reward 曲線




圖 5.4 固定初始 SOC 之 SOC std 曲線

5.2.1 固定 SOC 條件的核心觀察

固定 SOC 實驗確立了一個重要基準：DDPG 架構在對稱確定的起始條件下具備完整的收斂能力，且收斂速度優於 TD3+GRU。這說明 TD3 三項改進機制的價值不在於固定條件下的峰值表現，而在於應對起始狀態不確定性的穩健性，此假設將在 5.3 節直接驗證。

5.3 記憶模組與演算法之隨機初始 SOC

本節在隨機初始 SOC 條件[40%60%]下評估三組架構的泛化穩健性。每個 Episode 的起始 SOC 從均勻分佈中獨立取樣，代理人無法依賴固定起點形成刻板化的充放電策

略，必須根據各 MG 的實際 SOC 動態調整決策，此條件直接對應真實電網中無法預知停電前各 MG 能量狀態的運行場景，表 5.2 彙整三組架構在隨機初始 SOC 條件下的訓練結果，圖 5.5 圖 5.6 圖 5.7 分別為隨機初始 SOC 之 24 小時訓練恢復曲線、Reward 曲線、SOC std 曲線。

表 5.2 隨機初始 SOC 訓練結果彙整

方法	訓練回合數	後 500ep 平均獎勵	後 500ep GoodAvg	後 500ep SOC std	收斂
TD3+GRU	3500	4618.1±14.6	24.00	10.79	V
TD3+LSTM	5000	4080.4±616.6	21.39	15.91	X
DDPG+GRU	5000	4053.8±368.5	20.25	11.49	X

TD3+GRU 在隨機初始 SOC 條件下呈現穩健的漸進式收斂。訓練初期 ep500 評估 GoodAvg 僅 18.30，此後逐步提升，ep1000 達 23.47、G24%=73.3%，但 $\sigma_R=116.3$ 仍偏高，ep1500 達 23.70、G24%=70.0%，但 $\sigma_R=61.0$ 仍超門檻，反映策略在不同初始 SOC 下的表現尚不一致。ep2000 評估首次同時通過 GoodAvg=24.00 與 $\sigma_R=18.8$ ，進入第 1 輪確認，此後 ep2500 至 ep3500 連續三次評估同一凍結 checkpoint，在 ep3500 完成第 4 輪確認，訓練收斂。收斂後的後 500ep 平均獎勵 4618.1 高於固定 SOC 條件 4473.8，顯示多樣化初始條件訓練使代理人習得更具泛化能力的調度策略。

DDPG+GRU 在隨機初始 SOC 條件下的表現急劇惡化。ep1000 曾達 G24%=40.0%、GoodAvg=23.13，為整個訓練過程的唯一有意義峰值；ep2000 即發生災難性崩潰 GoodAvg=14.57、 $\sigma_R=1831.2$ ，策略在 30 個評估 Episode 間的表現差異達到 1831.2 的極端水準。此後雖逐漸恢復至 GoodAvg=21 至 23 的區間，但 G24%始終維持 0%，整個訓練過程再未出現任何 Episode 達到 GoodAvg=24.0。此結果直接量化了 TD3 截斷雙 Critic、目標策略平滑化與延遲策略更新三項改進在應對隨機初始條件上的必要性：DDPG 的單 Critic 架構在每回合不同 SOC 起點下，Q 值高估偏差被初始狀態的隨機性持續放大，策略梯度方向持續混亂。

TD3+LSTM 在隨機 SOC 條件下全程 G24%未超過 6.7%，ep1000 唯一例外，且 σ_R 在整個訓練過程中劇烈波動，ep3000 達 993.7、ep3500 更達 1161.2，交替出現深度崩潰於 ep3000：GoodAvg=17.73、ep3500：GoodAvg=19.20 與短暫恢復於 ep4500：GoodAvg=22.33。相較於固定初始 SOC 條件，LSTM 在多樣化初始條件下細胞狀態的初始化不一致性更為嚴重，無法在不同初始 SOC 之間形成穩定的時序記憶基礎。




圖 5.5 隨機初始 SOC 之 24 小時恢復曲線




圖 5.6 隨機初始 SOC 之 Reward 曲線




圖 5.7 隨機初始 SOC 之 SOC std 曲線

5.3.1 固定 SOC 與隨機 SOC 的對比分析

表 5.3 為固定 SOC 與隨機 SOC 後 500ep GoodAvg 對比

表 5.3 固定初始 SOC 與隨機初始 SOC 後 500ep GoodAvg 對比

方法	固定 SOC	隨機 SOC
TD3+GRU	24.00 (收斂)	24.00 (收斂)
TD3+LSTM	23.56 (未收斂)	21.39 (未收斂)
DDPG+GRU	24.00 (收斂)	20.25 (未收斂)

此對比清楚說明 TD3 三項改進機制的核心價值：固定 SOC 條件下 DDPG 具備完整收斂能力，但引入初始狀態不確定性後立即崩潰，其 GoodAvg 下降 3.75。

TD3+GRU 在兩種條件下均維持 GoodAvg=24.00，驗證了三項改進機制對隨機初始條件的完整穩健性。TD3+LSTM 在兩種條件下均未收斂且隨機 SOC 條件下進一步惡化，確認 GRU 在短序列多樣化條件下相較 LSTM 的穩定性優勢。

5.4 PC 共識參數比較

本節在隨機初始 SOC 條件下，對 PC 共識機制的自身保留係數進行系統性比較，驗證 PC 機制的必要性以及非對稱係數設計的合理性。所有配置均採用 TD3+GRU 架構

與 $a_{self}=0.6$ ，僅改變 PC 共識比例，表 5.4 為隨機初始 SOC 之 PC 共識參數訓練結果，圖 5.8 圖 5.9 圖 5.10 分別為各 PC 共識參數訓練之 24 小時訓練恢復曲線、Reward 曲線、SOC std 曲線。

表 5.4 PC 共識參數訓練結果

配置	訓練回合數	後 500ep 平均 獎勵	後 500ep GoodAvg	後 500ep SOC std	收斂
NoPC	5000	3193.3±1059.8	14.92	13.16	X
PC 0.7/0.7	5000	3697.4±615.4	18.30	25.35	X
PC 0.8/0.8	5000	2916.3±1052.9	12.08	18.95	X
PC 0.8/0.85 (主方法)	3500	4618.1±14.6	24.00	10.79	V
PC 0.9/0.9	5000	3982.7±340.4	19.94	20.38	X

無 PC 對照組的後 500ep GoodAvg 均值僅 14.92，後 500ep 獎勵標準差高達 1059.8。確定性評估記錄顯示，策略在 ep1500 的評估中曾達 $G24\%=63.3\%$ ，但 ep2000 即發生崩潰於 GoodAvg=15.30、 $\sigma_R=1030.9$ ，此後策略品質持續低迷。在缺乏 PC 機制的情況下，5 個代理人的策略完全依賴各自的本地訓練信號獨立演化，跨 MG 的 Tie-line 協調所需的意圖一致性無法自然形成，AND 投票機制的協調失敗率居高不下，策略整體陷入低品質的不穩定均衡。

PC 0.7/0.7 的後 500ep GoodAvg=18.30，後 500ep 獎勵標準差達 615.4，SOC std=25.35 超出上限 20.0。確定性評估中策略在 ep1500 曾達 $G24\%=50.0\%$ ，但此時 $\sigma_R=186.9$ 遠超收斂門檻，訓練過程中 σ_R 多次超過 1000，顯示過度激進的共識使各代理人喪失應對局部差異的調適能力，策略在收縮與崩潰之間反覆循環，能量分配嚴重失衡。

PC 0.8/0.8 的後 500ep GoodAvg 僅 12.08，後 500ep 獎勵標準差高達 1052.9，是所有配置中表現最差的結果。確定性評估中策略在 ep1000 曾達 $G24\%=46.7\%$ ，此時 σ_R

=106.1 仍遠超收斂門檻，反映策略在 30 個評估 Episode 間的一致性嚴重不足。此組與主方法的對比最具說服力：兩者的 Actor 自身保留係數完全相同，差異僅在於 Critic 係數由 0.80 提升至 0.85，主方法即達到後 500ep GoodAvg=24.00，而 PC 0.8/0.8 的後 500ep GoodAvg 僅 12.08，後 500ep 獎勵標準差亦高達 1052.9。此精確對照量化了 Critic 穩定性對訓練收斂的決定性影響：Critic 負責 Q 值估計，較激進的 Critic 共識使各代理人的 Bellman 目標相互干擾，Actor 梯度方向持續混亂。

PC 0.9/0.9 呈現所有配置中最複雜的失敗模式：後 500ep GoodAvg=19.94 看似接近收斂水準，但後 500ep 獎勵標準差達 340.4，且訓練最終以策略退化至穩定次佳局部解告終。確定性評估記錄揭示了這一過程的完整細節，其策略先後歷經兩次收斂嘗試週期，每次均進入四輪確認並通過前兩輪，卻始終無法完成第 3 至第 4 輪確認。兩次週期間 SOC std 從 11.3 漂移至 7.5，揭示了策略能量協調均衡性的根本不穩定性：PC 0.9/0.9 的保守共識，其每次僅混合 10% 的鄰居參數，雖能在短期內維持高 G24%，卻無法形成一個在能量均衡性上持續穩定的收斂策略，策略在不同嘗試間對跨 MG 能量分配的決策存在系統性漂移。最終，ep3500 的確定性評估顯示 GoodAvg 急降至 19.0，且 σ_R 僅 6.1，其策略退化成一個極度一致但完全錯誤的固定模式，完全失去動態調適能力。




圖 5.8 各 PC 共識參數訓練之 24 小時恢復曲線




圖 5.9 各 PC 共識參數訓練之 Reward 曲線




圖 5.10 各 PC 共識參數訓練之 SOC std 曲線

5.4.1 主方法 PC 0.8/0.85 設計驗證

主方法 PC 0.8/0.85 在 ep2000 完成第 1 輪確認，並在 ep2500 至 ep3500 連續通過第 2 至第 4 輪確認，完成穩定收斂。在 Actor 係數固定 0.8 的嚴格控制條件下，僅 Critic 係數由 0.80 提升至 0.85，即可從後 500ep GoodAvg=12.08 轉變為後 500ep GoodAvg=24.00 的穩定收斂，驗證了 Critic 穩定性在 PC 架構中的決定性地位，以及非對稱係數設計的合理性

5.5 GNN 自身/鄰居聚合比例比較

本節在隨機初始 SOC 條件下，對 GNN 的自身/鄰居聚合比例 a_{self} ，從 0.2 至 1.0 共

五個配置進行系統性比較，確定有效收斂區間並選定最優值。所有配置均採用 TD3+GRU 架構與主方法 PC 參數與隨機初始 SOC，僅改變 a_{self} ，表 5.5 為各 a_{self} 訓練結果彙整，圖 5.11 圖 5.12 圖 5.13 為各 a_{self} 訓練配置之 24 小時訓練恢復曲線與 Reward 曲線。

表 5.5 各 a_{self} 訓練結果彙整

配置	訓練回合數	後 500ep 平均 獎勵	後 500ep GoodAvg	後 500ep SOC_std	收斂
0.2	5000	3801±967.2	19.49	29.60	X
0.4	3000	4524.0±8.8	24.00	16.57	V
0.6 (主方法)	3500	4618.1±14.6	24.00	10.79	V
0.8	5000	3526.8±869.0	17.79	31.55	X
1.0	5000	3793.2±904.8	19.57	20.05	X

實驗結果顯示 a_{self} 的有效收斂區間為[0.4, 0.6]，兩端配置均未能收斂，且各自呈現不同的失敗特徵。

$a_{self}=0.2$ 的後 500ep GoodAvg=19.49，後 500ep 獎勵標準差達 967.2，後 500ep SOC std=29.60 遠超上限 20.0。確定性評估中策略在 ep2000 曾達 G24%=43.3%，但此時 $\sigma_R=81.2$ 遠超收斂門檻，且 SOC std=6.4 低於 8.0 下限，反映過度依賴鄰居的平均觀測使代理人無法根據自身局部 ESS 狀況進行精確調度，各 MG 的充放電決策趨於均一化而缺乏差異化的跨 MG 協調。

$a_{self}=0.8$ 的後 500ep GoodAvg=17.79，後 500ep 獎勵標準差達 869.0，後 500ep SOC std=31.55 為所有配置中最高，顯示能量分配嚴重失衡。確定性評估記錄顯示，ep1500 和 ep2000 兩次評估結果完全相同，G24%=100%且 $\sigma_R=11.9$ ，然而凍結策略的評估 SOC

std=21.4 超過 20.0 上限，顯示 $a_{self}=0.8$ 的高自身比重使各 MG 傾向過度自主放電而缺乏跨 MG 能量調配，能量分配均衡性不足。ep2500 評估 GoodAvg 立即降至 23.2，此後策略急速退化，其 ep3500 GoodAvg=17.8，確定性評估中 G24%在 ep2500 後完全歸零，後 500ep GoodAvg 最終僅 17.79。 $a_{self}=0.8$ 的案例說明，能量協調均衡性的缺陷在凍結評估中即已顯現，並在凍結解除後導致不可逆的策略退化。

$a_{self}=1.0$ 的後 500ep GoodAvg=19.57 但後 500ep 獎勵標準差達 904.8，訓練過程中 σ_R 多次發生災難性飆升於 ep2000：1100.7、ep3500：1221.6、ep4000：1930.5，確定性評估中 G24%從未超過 10%，訓練完全無法形成穩定的復電策略，直接驗證了 GNN 空間聚合對跨 MG 協調的不可缺少性。




圖 5.11 各 a_{self} 訓練配置之 24 小時恢復曲線




圖 5.12 各 a_{self} 訓練配置之 Reward 曲線




圖 5.13 各 a_{self} 訓練配置之 SOC std 曲線

5.5.1 最優 α_{self} 的選定

在有效區間 $[0.4, 0.6]$ 內，兩者均通過四輪確認，但收斂過程有所差異。確定性評估記錄顯示， $a_{self}=0.4$ 在 ep1500 首次通過所有確認條件，在 ep3000 完成第 4 輪確認；

$a_{self}=0.6$ 在 ep2000 首次通過，在 ep3500 完成第 4 輪確認，收斂速度略慢。

然而，比較兩組的後 500ep 訓練統計， $a_{self}=0.6$ 的後 500ep 平均獎勵 4618.1 高於 $a_{self}=0.4$ 的 4524.0，後 500ep SOC std=10.79 亦優於 $a_{self}=0.4$ 的 16.57，說明 $a_{self}=0.6$ 雖進入四輪確認的時間較晚，但收斂後的策略在整體訓練品質與能量均衡性上均更為優越，確立為主方法的最終設定。

$a_{self}=0.6$ 的設計含義在於：代理人以 60%的比重信任自身的直接觀測，以 40%的比重納入鄰居的空間聚合特徵，其提供跨 MG 能量狀態感知，但因動作資訊不可得而因果資訊不完整，因此在 DTDE 框架的資訊限制下取得合理平衡。

5.6 代理人行為分析

本節選取隨機初始 SOC 的 TD3+GRU 主方法收斂後的一個典型評估 Episode，呈現策略在 24 小時操作週期內的具體行為模式，驗證代理人是否學到了符合物理直覺的

能量調度策略。該 Episode 全程維持三個關鍵負載同步復電，一般負載切除量為零，達到完美復電表現。

5.6.1 PV 出力與 ESS 充放電行為

圖 5.14 呈現各 MG 的 PV 曲線、load 曲線、一般負載截斷量，圖 5.15 呈現各 MG 的 ESS SOC 在 24 小時操作週期內的軌跡，圖 5.16 呈現各 MG 的 ESS SOC 的充放電軌跡。因 07:00 才真正有 PV 輸出，因此系統在 06:00 時各 MG 潮流後的 SOC 分布於 37.2%至 45.6%之間，反映隨機初始 SOC 條件下的典型起始狀態。

PV 出力從 06:00 起逐漸上升，但真正獲得 PV 要從 07:00 開始，於 11:00 至 12:00 達到全系統峰值，並於 17:00 降至零，進入無 PV 出力的夜間時段。各 MG 代理人對這一日間能量週期的學習結果在 SOC 軌跡中清楚可見：MG1、MG2、MG3 分別在 13:00、13:00 與 12:00 達到 100%滿充，MG0 在 16:00 達到 90.5%峰值，顯示代理人學會利用 PV 盈餘積極充電以備夜間供電。

MG4 呈現一個值得注意的特殊行為：06:00 至 09:00 期間 SOC 從 42.9%持續下降至 15.7%，顯示代理人在 PV 出力尚未充分建立的早晨時段，主動讓 MG4 的 ESS 承擔孤島內的功率缺口；09:00 後隨著 PV 出力提升，MG4 轉為充電模式，至 17:00 達到 100%滿充，累計充電幅度達 84.3%。此「先放後充」的非對稱策略反映代理人基於 GRU 時序記憶，在早晨時段已預判日間 PV 的充電能力，主動安排 MG4 在短暫放電後仍能完整充滿。

5.6.2 夜間放電與 ESS 能量管理

夜間時段 18:00 至 05:00，各 MG ESS 依序放電以維持孤島內的關鍵負載供電，全程維持三個關鍵負載同步復電。各 MG 的放電速率與末步剩餘電量呈現明顯的差異化分布，反映策略並非讓所有 MG 以相同比例消耗能量，而是根據各 MG 的能量容量與局部負載需求進行不同速率的調度，且為了關鍵負載復電，代理人必須根據電量的充

裕度對一般負載有所犧牲。

其中 MG2 始終保持最充裕的備援，整個夜間消耗速率最低；部分 MG 則在 Episode 結束前即達到能量耗盡。值得注意的是，即使個別 MG 的 ESS 在深夜提前耗盡，系統仍透過 Tie-line 的跨 MG 能量支援維持全程關鍵負載供電，顯示跨 MG 協調機制有效彌補了單一 MG 的能量不足。




圖 5.14 PV 曲線、load 曲線、一般負載截斷量




圖 5.15 SOC 電量曲線




圖 5.16 SOC 充/放電曲線

第六章 結論

6.1 研究成果與貢獻

本研究針對 IEEE 123-bus 配電測試系統的多微電網孤島復電問題，提出一套結合策略共識機制、圖神經網路與記憶網路之去中心化深度強化學習架構，在訓練與執行階段均不依賴集中式 Critic 的前提下，整合分散式執行、拓樸感知與時序預判三項能力，形成完整的多代理人復電決策框架。

6.1.1 架構設計貢獻

策略共識的非對稱設計：本研究提出 Actor 與 Critic 採用不同自身保留係數的非對稱 PC 設計，並透過系統性比較分析驗證其必要性。在 Actor 係數固定的嚴格控制條件下，僅將 Critic 係數由 0.80 提升至 0.85，即可使訓練從完全無法收斂轉變為穩定收斂，精確量化了 Critic 穩定性在 PC 共識架構中的決定性影響。此非對稱設計的物理依據在於：Actor 的策略方向需要快速跨代理人對齊，而 Critic 的 Q 值估計是 Actor 梯度更新的基礎，需要更高的穩定性方能確保正確的梯度方向。

GNN 加權局部聚合設計：本研究採用以固定係數 $a_{self}=0.6$ 區分自身與鄰居資訊貢獻比例的 GNN 聚合機制，比較分析實驗確定其有效收斂區間為 $a_{self} \in [0.4, 0.6]$ ，並驗證完全移除 GNN 空間聚合 $a_{self}=1.0$ 將導致訓練完全失敗，確認跨 MG 空間資訊融合的不可缺少性。

精英池雙池經驗回放記憶體架構：本研究設計以回合為單位的普通池與精英池雙池架構，以四項 AND 篩選條件嚴格篩選高品質軌跡，解決電網復電場景中 PandaPower 潮流計算代價高昂所導致的樣本效率問題，以及稀疏成功獎勵下訓練信號品質不均的挑戰。訓練時採精英池貢獻 25%、普通池貢獻 75% 的固定混合比例，在學習效率與探索多樣性之間取得平衡。

四輪確認收斂機制：本研究設計融合 GoodAvg、獎勵標準差與末步 SOC std 三項條件的四輪確認機制，有效避免訓練過程中偶發高分造成的誤判收斂。機制設計要求策略在連續四次確定性評估中均同時滿足完美復電、輸出一致性與能量均衡三項標準，確保最終輸出的策略具備跨多樣化初始條件的穩定泛化能力。

6.1.2 實驗結果貢獻

隨機初始條件下的穩健收斂：在隨機初始 SOC 條件下，主方法 TD3+GRU 為三組比較分析架構中唯一成功收斂的配置，後 500ep 平均獎勵 4618.1，全程維持 30 個確定性評估 Episode 的 GoodAvg=24.00 與 Rst3=100%。相較之下，DDPG+GRU 在 ep2000 遭遇 $\sigma_R=1831.2$ 的災難性崩潰，TD3+LSTM 全程 G24%未超過 6.7%，充分驗證 TD3 三項改進機制：截斷雙 Critic、目標策略平滑化、延遲策略更新，對隨機起始狀態的不可缺少性。

物理約束的完整遵守：主方法 TD3+GRU 收斂後的確定性評估顯示，所有 30 個評估 Episode 在 720 個操作步驟中，電壓越限次數為零、線路電流越限次數為零、Virtual Slack 超額定次數為零，且所有 MG 的 KCL 誤差均低於 0.00001 MW，在完整遵守物理約束的前提下實現完美復電，驗證了強化學習策略在配電網物理可行性上的可靠性。

代理人行為的可解釋性：收斂後的策略呈現符合物理直覺的能量調度行為—白天利用 PV 盈餘積極充電、夜間根據各 MG 的負載密度與能量容量進行差異化放電，並在預判到能量不足之前提前建立 Tie-line 支援通道，體現了 GRU 時序記憶在前瞻性協調決策中的有效作用。

6.2 未來展望

本研究建立了多微電網分散式復電的基礎框架，然而仍存在值得後續深化的方向：

- 超參數的自適應學習：本研究的 PC 共識保留係數與 GNN 自身/鄰居聚合比例

a_{self} ，均透過系統性比較分析實驗手動選定最優值，此過程需要對每組候選參數重複完整的訓練流程，耗費大量計算資源與時間成本。後續可探索將這些係數設計為可學習參數，例如以額外的小型網路根據當前訓練狀態動態調整 PC 係數，或讓 a_{self} 隨訓練進程自適應演化，使架構在面對不同任務目標或拓撲規模時，不需要重複進行耗時的比較分析實驗即可自動收斂至合適的設定。

- 收斂後策略穩定性的保障：本研究設計了崩潰恢復機制與四輪確認收斂判定，以緩解 Q 值漂移與策略退化問題。然而從訓練曲線中觀察到，部分超參數配置的策略在短暫達到完美復電後仍出現退化，顯示收斂後的長期穩定性仍有進一步提升的空間。後續可探索更嚴格的早停機制結合最佳 checkpoint 保存策略，或引入保守策略更新以限制策略更新幅度，從演算法層面提升收斂後的穩定性保障。
- 更大規模系統的可擴展性驗證：本研究在 5 個微電網代理人的系統上驗證了架構的有效性。PC 共識機制在理論上具備與代理人數量無關的可擴展性，後續可在更大規模的測試系統如 IEEE 8500-bus 或更多 MG 分區的配置上進行驗證，評估架構在系統規模增加時的訓練穩定性與收斂品質。

參考文獻

- [1] M. Panteli and P. Mancarella, "The Grid: Stronger, Bigger, Smarter?: Presenting a Conceptual Framework of Power System Resilience," *IEEE Power and Energy Magazine*, vol. 13, no. 3, pp. 58–66, 2015, doi: 10.1109/MPE.2015.2397334.
- [2] X. Fang, S. Misra, G. Xue, and D. Yang, "Smart Grid — The New and Improved Power Grid: A Survey," *IEEE Communications Surveys & Tutorials*, vol. 14, no. 4, pp. 944–980, 2012, doi: 10.1109/SURV.2011.101911.00087.
- [3] D. Hu, Z. Li, Z. Ye, Y. Peng, W. Xi, and T. Cai, "Multi-agent graph reinforcement learning for decentralized Volt-VAR control in power distribution systems," *International Journal of Electrical Power & Energy Systems*, vol. 155, 2024, doi: 10.1016/j.ijepes.2023.109531.
- [4] A. Khodaei, "Resiliency-Oriented Microgrid Optimal Scheduling," *IEEE Transactions on Smart Grid*, vol. 5, no. 4, pp. 1584–1591, 2014, doi: 10.1109/TSG.2014.2311465.
- [5] R. S. Sutton and A. G. Barto, *Reinforcement Learning: An Introduction*, 2nd ed. Cambridge, MA, 2018.
- [6] B. Fan, X. Liu, G. Xiao, Y. Xu, X. Yang, and P. Wang, "A Memory-Based Graph Reinforcement Learning Method for Critical Load Restoration With Uncertainties of Distributed Energy Resource," *IEEE Transactions on Smart Grid*, vol. 16, no. 2, pp. 1706–1718, 2025, doi: 10.1109/tsg.2024.3482696.
- [7] R. Si, S. Chen, J. Zhang, J. Xu, and L. Zhang, "A multi-agent reinforcement learning method for distribution system restoration considering dynamic network reconfiguration," *Applied Energy*, vol. 372, 2024, doi: 10.1016/j.apenergy.2024.123625.
- [8] R. Lowe, J. Harb, Y. Wu, P. Abbeel, A. Tamar, and I. Mordatch, "Multi-Agent Actor-Critic for Mixed Cooperative-Competitive Environments," presented at the Advances in Neural Information Processing Systems (NeurIPS), 2017.
- [9] Y. Hu, J. Fu, G. Wen, and C. Sun, "Policy Consensus-Based Distributed Deterministic Multi-Agent Reinforcement Learning Over Directed Graphs," *IEEE Transactions on Artificial Intelligence*, vol. 6, no. 1, pp. 118–131, 2025, doi: 10.1109/tai.2024.3452678.
- [10] D. Silver, G. Lever, N. Heess, T. Degris, D. Wierstra, and M. Riedmiller, "Deterministic Policy Gradient Algorithms," presented at the Proceedings of the 31st International Conference on Machine Learning (ICML), 2014/01/27, 2014. [Online]. Available: <https://proceedings.mlr.press/v32/silver14.html>.
- [11] T. P. Lillicrap *et al.*, "Continuous Control with Deep Reinforcement Learning,"

- presented at the International Conference on Learning Representations (ICLR), 2016.
- [12] S. Fujimoto, H. van Hoof, and D. Meger, "Addressing Function Approximation Error in Actor-Critic Methods," presented at the Proceedings of the 35th International Conference on Machine Learning (ICML), 2018.
 - [13] D. S. Bernstein, R. Givan, N. Immerman, and S. Zilberstein, "The Complexity of Decentralized Control of Markov Decision Processes," *Mathematics of Operations Research*, vol. 27, no. 4, pp. 819–840, 2002, doi: 10.1287/moor.27.4.819.297.
 - [14] V. Mnih *et al.*, "Human-level control through deep reinforcement learning," *Nature*, vol. 518, no. 7540, pp. 529–533, 2015/02/01 2015, doi: 10.1038/nature14236.
 - [15] H. v. Hasselt, A. Guez, and D. Silver, "Deep Reinforcement Learning with Double Q-Learning," *Deep Reinforcement Learning with Double Q-learning*, 2015. [Online]. Available: <https://api.semanticscholar.org/CorpusID:6208256>.
 - [16] Y. Bengio, P. Simard, and P. Frasconi, "Learning long-term dependencies with gradient descent is difficult," *IEEE Transactions on Neural Networks*, vol. 5, no. 2, pp. 157–166, 1994, doi: 10.1109/72.279181.
 - [17] S. Hochreiter and J. Schmidhuber, "Long Short-Term Memory," *Neural Computation*, vol. 9, no. 8, pp. 1735–1780, 1997, doi: 10.1162/neco.1997.9.8.1735.
 - [18] K. Cho *et al.*, "Learning Phrase Representations using RNN Encoder-Decoder for Statistical Machine Translation," presented at the Proceedings of the 2014 Conference on Empirical Methods in Natural Language Processing (EMNLP), 2014.
 - [19] T. N. Kipf and M. Welling, "Semi-Supervised Classification with Graph Convolutional Networks," presented at the International Conference on Learning Representations (ICLR), 2017.
 - [20] W. L. Hamilton, R. Ying, and J. Leskovec, "Inductive Representation Learning on Large Graphs," presented at the Advances in Neural Information Processing Systems (NeurIPS), 2017.
 - [21] T. Schaul, J. Quan, I. Antonoglou, and D. Silver, "PRIORITIZED EXPERIENCE REPLAY," presented at the International Conference on Learning Representations (ICLR), 2016.
 - [22] L. Thurner *et al.*, "Pandapower—An Open-Source Python Tool for Convenient Modeling, Analysis, and Optimization of Electric Power Systems," *IEEE Transactions on Power Systems*, vol. 33, no. 6, pp. 6510–6521, 2018, doi: 10.1109/TPWRS.2018.2829021.
 - [23] R. D. Zimmerman, C. E. Murillo-Sánchez, and R. J. Thomas, "MATPOWER: Steady-State Operations, Planning, and Analysis Tools for Power Systems Research and Education," *IEEE Transactions on Power Systems*, vol. 26, no. 1, pp. 12–19, 2011, doi: 10.1109/TPWRS.2010.2051168.
 - [24] R. C. Dugan and D. Montenegro, "The Open Distribution System Simulator

- (OpenDSS) Reference Guide," Electric Power Research Institute (EPRI), 2020.
- [25] D. P. Chassin, K. Schneider, and C. Gerkenmeyer, "GridLAB-D: An open-source power systems modeling and simulation environment," in *2008 IEEE/PES Transmission and Distribution Conference and Exposition*, 21–24 April 2008 2008, pp. 1–5, doi: 10.1109/TDC.2008.4517260.
 - [26] M. E. Baran and F. F. Wu, "Network reconfiguration in distribution systems for loss reduction and load balancing," *IEEE Transactions on Power Delivery*, vol. 4, no. 2, pp. 1401–1407, 1989, doi: 10.1109/61.25627.
 - [27] C. Chen, J. Wang, F. Qiu, and D. Zhao, "Resilient Distribution System by Microgrids Formation After Natural Disasters," *IEEE Transactions on Smart Grid*, vol. 7, no. 2, pp. 958–966, 2016, doi: 10.1109/TSG.2015.2429653.
 - [28] K. P. Schneider *et al.*, "Analytic Considerations and Design Basis for the IEEE Distribution Test Feeders," *IEEE Transactions on Power Systems*, vol. 33, no. 3, pp. 3181–3188, 2018, doi: 10.1109/TPWRS.2017.2760011.
 - [29] M. Barani, J. Aghaei, M. A. Akbari, T. Niknam, H. Farahmand, and M. Korpås, "Optimal Partitioning of Smart Distribution Systems Into Supply-Sufficient Microgrids," *IEEE Transactions on Smart Grid*, vol. 10, no. 3, pp. 2523–2533, 2019, doi: 10.1109/TSG.2018.2803215.
 - [30] S. Kapturowski, G. Ostrovski, J. Quan, R. Munos, and W. Dabney, "Recurrent Experience Replay in Distributed Reinforcement Learning," presented at the International Conference on Learning Representations (ICLR), 2019.